

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN - CƠ - TIN HỌC



MACHINE LEARNING

Chủ đề

DỰ ĐOÁN TUỔI THỌ TRUNG BÌNH
DỰA TRÊN CÁC YẾU TỐ Y TẾ - XÃ HỘI

Giảng viên hướng dẫn: TS. Cao Văn Chung

Nhóm sinh viên thực hiện:

<i>Họ và tên</i>	<i>MSSV</i>	<i>Lớp</i>
Đinh Quang Tiến	23001943	K68A4
Nguyễn Đức Quang	23001918	K68A4
Hà Minh Quang	23001916	K68A4

Hà Nội, 2026

Tóm Tắt Nội Dung

Dự án này tập trung vào việc ứng dụng các mô hình học máy để dự đoán tuổi thọ trung bình (Life Expectancy) dựa trên bộ dữ liệu Life Expectancy Data của Tổ chức Y tế Thế giới (WHO). Đây là một bài toán hồi quy điển hình, trong đó mục tiêu là dự đoán một giá trị liên tục dựa trên nhiều yếu tố y tế và xã hội như tỷ lệ tử vong người lớn, tỷ lệ tiêm chủng, GDP, chỉ số BMI, và nhiều yếu tố khác.

Phần đầu tiên của báo cáo trình bày cơ sở lý thuyết về các kỹ thuật tiền xử lý dữ liệu, bao gồm xử lý giá trị thiếu, chuẩn hóa dữ liệu, và mã hóa biến phân loại. Phần thứ hai tập trung vào các phương pháp giảm chiều, cụ thể là Phân tích thành phần chính (PCA) và lựa chọn đặc trưng với SelectKBest, nhằm giảm số chiều dữ liệu từ 20 features xuống không gian có chiều thấp hơn trong khi vẫn giữ lại phần lớn thông tin quan trọng.

Dữ liệu được chia thành tập huấn luyện (70%) và tập kiểm tra (30%) với 2938 quan sát từ 193 quốc gia trong giai đoạn 2000-2015. Sau khi tiền xử lý, PCA được áp dụng để giảm chiều từ 20 features xuống 15 thành phần chính, giữ lại 95% phương sai của dữ liệu gốc. SelectKBest được sử dụng để chọn ra 10 features quan trọng nhất dựa trên F-statistic. Kết quả cho thấy phương sai giải thích của PCA đạt 96.55% trên tập kiểm tra.

Báo cáo này nhấn mạnh tầm quan trọng của việc phân tích và xử lý dữ liệu y tế để xây dựng các mô hình dự đoán đáng tin cậy, góp phần hỗ trợ các nhà hoạch định chính sách trong việc đưa ra quyết định về đầu tư y tế và phát triển xã hội.

Mục lục

1	Lý do chọn đề tài	6
2	Tiền xử lý dữ liệu	7
2.1	Tổng quan về bộ dữ liệu	7
2.2	Xử lý giá trị thiếu	8
2.3	Mã hóa biến phân loại	9
2.4	Chuẩn hóa dữ liệu	10
3	Giảm chiều và trực quan hóa dữ liệu	12
3.1	Phân tích thành phần chính (PCA)	12
3.1.1	Mục đích	12
3.1.2	Cơ sở lý thuyết	12
3.1.3	Các bước thực hiện	13
3.1.4	Kết quả thực nghiệm	14
3.2	Lựa chọn đặc trưng với SelectKBest	16
3.2.1	Giới thiệu về SelectKBest	16
3.2.2	Phương pháp $f_{\text{regression}}$	16
3.2.3	Kết quả thực nghiệm	17
3.3	So sánh PCA và SelectKBest	17
4	Phương pháp hồi quy sử dụng KNN	19
4.1	Giới thiệu	19
4.2	Cách thuật toán KNN hoạt động trong bài toán hồi quy	19
4.2.1	Ý tưởng tổng quát	20
4.2.2	Tính khoảng cách giữa các điểm	20
4.2.3	Chuẩn hóa dữ liệu (Feature Scaling)	21
4.2.4	Cách tính giá trị dự đoán	21
4.2.5	Quy trình thuật toán (pseudocode)	21
4.2.6	Chọn giá trị k phù hợp	21
4.2.7	Đánh giá hiệu quả mô hình	22
4.2.8	Tóm tắt	22
4.3	Phương pháp KNN với bài toán hồi quy dự đoán tuổi thọ trung bình	22
4.3.1	Đánh giá hiệu suất mô hình theo các tỉ lệ chia dữ liệu	22
4.3.2	Kết quả thực nghiệm	22

4.3.3	Phân tích kết quả	23
4.3.4	Trực quan hóa phần dư	24
4.3.5	Nhận xét tổng quan	25
5	Phương pháp Linear Regression với bài toán hồi quy dự đoán tuổi thọ trung bình	26
5.1	Cách thuật toán Linear Regression hoạt động	26
5.1.1	Mô hình tổng quát	26
5.1.2	Hàm mất mát (Loss function)	26
5.1.3	Quá trình huấn luyện mô hình	27
5.1.4	Dự đoán giá trị tuổi thọ trung bình	27
5.1.5	Ưu và nhược điểm	27
5.2	Đánh giá hiệu suất mô hình theo các tỉ lệ chia dữ liệu	27
5.2.1	Kết quả thực nghiệm	28
5.2.2	Phân tích kết quả	28
5.2.3	Trực quan hóa phần dư	30
5.3	Nhận xét tổng quan	30
6	Phân cụm dữ liệu (K-MEANS & GMM)	32
6.1	Giới thiệu	32
6.2	Cơ sở lý thuyết	32
6.2.1	Thuật toán K-Means	32
6.2.1.1	Ý tưởng chính	32
6.2.1.2	Ký hiệu toán học	32
6.2.1.3	Hàm mất mát	33
6.2.1.4	Thuật toán tối ưu	33
6.2.1.5	Các bước thực hiện thuật toán K-Means	33
6.2.1.6	Tính hội tụ	34
6.2.1.7	Ưu điểm và hạn chế	34
6.2.2	Gaussian Mixture Model (GMM)	35
6.2.2.1	Ý tưởng chính	35
6.2.2.2	Mô hình toán học	35
6.2.2.3	Thuật toán Expectation-Maximization (EM)	35
6.2.2.4	Các bước thực hiện thuật toán GMM	36
6.2.2.5	Ưu điểm và hạn chế	37
6.2.3	So sánh K-Means và GMM	37
6.3	Các độ đo đánh giá chất lượng phân cụm	37
6.3.1	Elbow Method (Inertia)	37
6.3.2	Silhouette Score	38
6.3.3	Davies-Bouldin Index	38
6.3.4	Calinski-Harabasz Index	38
6.3.5	BIC và AIC (cho GMM)	39
6.3.6	ANOVA F-test	39
6.4	Thực nghiệm	40
6.4.1	Mô tả bộ dữ liệu	40

6.4.2	Tiền xử lý dữ liệu	40
6.4.3	Thiết lập thí nghiệm	40
6.5	Kết quả và phân tích	41
6.5.1	Lựa chọn số cụm K	41
6.5.1.1	Phân tích các chỉ số đánh giá	41
6.5.2	Kết quả phân cụm với $K=3$	42
6.5.3	Phân tích đặc trưng các cụm	42
6.5.4	Trực quan hóa dữ liệu bằng PCA	42
6.5.5	Phân tích đặc trưng của các cụm	43
6.5.6	Kiểm định ANOVA	44
6.6	Kết luận chương	44
7	Chuyên bài toán hồi quy về phân loại	46
7.1	Chuẩn bị dữ liệu	46
7.1.1	Kết quả phân cụm	46
7.1.2	Tạo nhãn phân loại	47
7.2	Các mô hình phân loại	48
7.2.1	Mô hình Logistic Regression	48
7.2.1.1	Giới thiệu	48
7.2.1.2	Cơ sở lý thuyết	48
7.2.1.3	Kết quả và đánh giá	50
7.2.2	Mô hình Naive Bayes	54
7.2.2.1	Giới thiệu	54
7.2.2.2	Cơ sở lý thuyết	54
7.2.2.3	Kết quả và đánh giá	56
7.3	So sánh hai mô hình Naive Bayes và Logistic Regression	60
7.3.1	Mô tả dữ liệu và thiết lập so sánh	60
7.3.2	So sánh theo chỉ số Accuracy	61
7.3.2.1	Trên dữ liệu gốc	61
7.3.2.2	Trên dữ liệu sau PCA	61
7.3.3	So sánh theo chỉ số F1-score	62
7.3.3.1	Trên dữ liệu gốc	62
7.3.3.2	Trên dữ liệu sau PCA	62
7.3.4	Đánh giá tổng hợp	63
8	Kết luận	64

Danh sách hình vẽ

3.1	Phân tán dữ liệu theo 2 thành phần chính đầu tiên (PC1 vs PC2).	14
3.2	Biểu đồ phân tán cho 6 cặp thành phần chính đầu tiên.	15
3.3	Tương quan giữa các thành phần chính (PC1–PC15) và đặc trưng gốc.	15
4.1	Mình hoạ thuật toán K-Nearest Neighbor.	19
4.2	So sánh giá trị R^2 trên tập kiểm định theo tỉ lệ chia dữ liệu.	23
4.3	So sánh độ chênh lệch ΔR^2 giữa tập huấn luyện và kiểm định.	24
4.4	Các biểu đồ trực quan hóa phần dư	24
5.1	So sánh giá trị R^2 trên tập kiểm định theo tỉ lệ chia dữ liệu.	29
5.2	So sánh độ chênh lệch ΔR^2 giữa tập huấn luyện và kiểm định.	29
5.3	Các biểu đồ trực quan hóa phần dư	30
6.1	Các chỉ số đánh giá cho K-Means và GMM	41
6.2	Phân bố Life Expectancy theo cụm	43
6.3	Trực quan hóa kết quả phân cụm bằng PCA 2D. PC1 giải thích 29.40% phương sai, PC2 giải thích 13.28% phương sai.	43
6.4	Heatmap: Đặc trưng các cụm so với trung bình chung (Z-score)	44
7.1	So sánh các cụm Kmeans và GMM	46
7.2	So sánh Accuracy (Test) của Logistic Regression giữa dữ liệu gốc và dữ liệu sau PCA	51
7.3	Confusion matrix của mô hình Logistic Regression tại tỉ lệ chia 7:3 (dữ liệu gốc)	52
7.4	Confusion matrix của mô hình Logistic Regression tại tỉ lệ chia 7:3 (dữ liệu giảm chiều pca)	52
7.5	Chênh lệch Accuracy giữa tập Train và Test của mô hình Logistic Regression	53
7.6	So sánh Accuracy (Test) của Naive Bayes giữa dữ liệu gốc và dữ liệu sau PCA	57
7.7	Confusion matrix của mô hình Naive Bayes tại tỉ lệ chia 7:3 (dữ liệu gốc)	57
7.8	Confusion matrix của mô hình Naive Bayes tại tỉ lệ chia 7:3 (dữ liệu giảm chiều pca)	58
7.9	Chênh lệch Accuracy giữa tập Train và Test của mô hình Naive Bayes	59
7.10	Tổng quan dữ liệu	60
7.11	So sánh Accuracy của Naive Bayes và Logistic Regression trên dữ liệu gốc	61
7.12	So sánh Accuracy của Naive Bayes và Logistic Regression trên dữ liệu sau PCA	61
7.13	So sánh F1-score của Naive Bayes và Logistic Regression trên dữ liệu gốc	62
7.14	So sánh F1-score của Naive Bayes và Logistic Regression trên dữ liệu sau PCA	62

Chương 1

Lý do chọn đề tài

Tuổi thọ trung bình là một chỉ số quan trọng phản ánh mức độ phát triển kinh tế - xã hội và chất lượng hệ thống y tế của một quốc gia. Theo Tổ chức Y tế Thế giới (WHO), tuổi thọ trung bình toàn cầu đã tăng đáng kể trong những thập kỷ qua, nhưng vẫn tồn tại sự chênh lệch lớn giữa các quốc gia và khu vực. Việc hiểu rõ các yếu tố ảnh hưởng đến tuổi thọ có ý nghĩa quan trọng trong việc hoạch định chính sách y tế, phân bổ nguồn lực và cải thiện chất lượng cuộc sống của người dân.

Trong bối cảnh dữ liệu y tế ngày càng phong phú và công nghệ học máy phát triển mạnh mẽ, việc ứng dụng các kỹ thuật phân tích dữ liệu và mô hình hóa dự đoán trở thành công cụ đắc lực để khám phá các mối quan hệ phức tạp giữa các yếu tố y tế - xã hội và tuổi thọ. Các mô hình học máy có khả năng xử lý dữ liệu đa chiều, phát hiện các mẫu tiềm ẩn mà phương pháp thống kê truyền thống khó nhận ra.

Đề tài này sử dụng bộ dữ liệu Life Expectancy Data từ WHO, bao gồm thông tin từ 193 quốc gia trong giai đoạn 2000-2015, với 22 biến số liên quan đến y tế, kinh tế và xã hội. Đây là một bài toán hồi quy điển hình, trong đó mục tiêu là dự đoán tuổi thọ trung bình dựa trên các yếu tố như tỷ lệ tử vong người lớn, tỷ lệ tử vong trẻ sơ sinh, tỷ lệ tiêm chủng, GDP, chỉ tiêu y tế, tình trạng dinh dưỡng, và mức độ giáo dục.

Thông qua việc triển khai các bước tiền xử lý dữ liệu (xử lý giá trị thiếu, mã hóa biến phân loại, chuẩn hóa), áp dụng các kỹ thuật giảm chiều (PCA, SelectKBest), và xây dựng các mô hình học máy, dự án không chỉ giúp người học nâng cao kỹ năng thực hành mà còn đóng góp vào việc hiểu sâu hơn về các nhân tố quyết định tuổi thọ con người.

Chương 2

Tiền xử lý dữ liệu

2.1 Tổng quan về bộ dữ liệu

Bộ dữ liệu Life Expectancy Data được thu thập từ Tổ chức Y tế Thế giới (WHO) và các nguồn dữ liệu thống kê của Liên Hợp Quốc, bao gồm thông tin từ 193 quốc gia trong giai đoạn từ năm 2000 đến 2015. Dữ liệu gồm **2938 quan sát** và **22 biến số**, trong đó biến mục tiêu (target) là **Life expectancy** (tuổi thọ trung bình).

Các biến trong bộ dữ liệu:

- a) **Country**: Tên quốc gia (193 giá trị unique)
- b) **Year**: Năm thu thập dữ liệu (2000-2015)
- c) **Status**: Trạng thái phát triển (Developed/Developing)
- d) **Life expectancy**: Tuổi thọ trung bình (năm) - *Biến mục tiêu*
- e) **Adult Mortality**: Tỷ lệ tử vong người lớn (trên 1000 dân)
- f) **infant deaths**: Số trẻ sơ sinh tử vong (trên 1000 dân)
- g) **Alcohol**: Tiêu thụ rượu bình quân đầu người (lít)
- h) **percentage expenditure**: Chi tiêu y tế chiếm % GDP
- i) **Hepatitis B**: Tỷ lệ tiêm chủng viêm gan B (%)
- j) **Measles**: Số ca sởi (trên 1000 dân)
- k) **BMI**: Chỉ số khối cơ thể trung bình
- l) **under-five deaths**: Số trẻ dưới 5 tuổi tử vong (trên 1000 dân)
- m) **Polio**: Tỷ lệ tiêm chủng bại liệt (%)
- n) **Total expenditure**: Tổng chi tiêu y tế chiếm % GDP
- o) **Diphtheria**: Tỷ lệ tiêm chủng bạch hầu (%)
- p) **HIV/AIDS**: Số ca tử vong do HIV/AIDS (trên 1000 dân)
- q) **GDP**: GDP bình quân đầu người (USD)

- r) **Population**: Dân số quốc gia
- s) **thinness 1-19 years**: Tỷ lệ suy dinh dưỡng ở trẻ 1-19 tuổi (%)
- t) **thinness 5-9 years**: Tỷ lệ suy dinh dưỡng ở trẻ 5-9 tuổi (%)
- u) **Income composition of resources**: Chỉ số phân bổ thu nhập (0-1)
- v) **Schooling**: Số năm học trung bình

Thống kê mô tả biến mục tiêu:

Biến Life expectancy có các đặc điểm sau:

- Số quan sát: 2928 (có 10 giá trị thiếu)
- Giá trị trung bình: 69.22 năm
- Độ lệch chuẩn: 9.52 năm
- Giá trị nhỏ nhất: 36.3 năm
- Trung vị: 72.1 năm
- Giá trị lớn nhất: 89.0 năm

Phân bố của biến mục tiêu cho thấy dữ liệu có phân phối tương đối cân đối, với giá trị trung bình và trung vị gần nhau (69.22 và 72.1), cho thấy phân phối không bị lệch đáng kể. Tuy nhiên, khoảng cách từ giá trị nhỏ nhất (36.3) đến giá trị lớn nhất (89.0) khá lớn, phản ánh sự chênh lệch về tuổi thọ giữa các quốc gia.

2.2 Xử lý giá trị thiếu

Một trong những thách thức chính khi làm việc với dữ liệu thực tế là vấn đề giá trị thiếu (missing values). Trong bộ dữ liệu này, tổng cộng có **2563 giá trị thiếu** (chiếm 3.97% tổng số dữ liệu), phân bố không đều qua các biến.

Phân tích giá trị thiếu:

Các biến có số lượng giá trị thiếu cao nhất được liệt kê trong bảng:

Biến	Số giá trị thiếu	Tỷ lệ (%)
Population	652	22.19
Hepatitis B	553	18.82
GDP	448	15.25
Total expenditure	226	7.69
Alcohol	194	6.60
Income composition of resources	167	5.68
Schooling	163	5.55
BMI, thinness 1-19, thinness 5-9	34	1.16
Polio, Diphtheria	19	0.65
Life expectancy, Adult Mortality	10	0.34

Bảng 2.1: Phân tích giá trị thiếu theo biến

Phương pháp xử lý:

Để xử lý giá trị thiếu, nhóm áp dụng phương pháp **Mean Imputation** (điền bằng giá trị trung bình) sử dụng SimpleImputer từ thư viện scikit-learn. Đây là một phương pháp phổ biến và phù hợp cho dữ liệu số, dựa trên công thức:

$$x_{missing} = \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i \quad (2.1)$$

Trong đó:

- $x_{missing}$ là giá trị cần điền
- $\bar{x}$ là giá trị trung bình của cột
- N là số quan sát có giá trị (không thiếu)

Quy trình thực hiện:

- Xử lý biến mục tiêu trước:** Điền 10 giá trị thiếu trong cột Life expectancy bằng giá trị trung bình 69.22 năm.
- Xử lý các biến số:** Áp dụng Mean Imputation cho 18 biến số còn lại (loại trừ Year vì không có giá trị thiếu).
- Kiểm tra kết quả:** Sau khi xử lý, số lượng giá trị thiếu giảm từ 2563 xuống 0, đảm bảo dữ liệu hoàn chỉnh cho các bước tiếp theo.

2.3 Mã hóa biến phân loại

Trong bộ dữ liệu có hai biến phân loại (categorical variables): **Country** và **Status**.

Xử lý biến Country:

Biến Country có 193 giá trị unique (tương ứng với 193 quốc gia). Nếu áp dụng One-Hot Encoding, sẽ tạo ra 192 cột dummy mới, dẫn đến:

- **Curse of dimensionality:** Số chiều tăng đột biến
- **Overfitting:** Mô hình dễ học thuộc lòng dữ liệu huấn luyện
- **Multicollinearity:** Các biến dummy có tương quan cao với nhau

Do đó, nhóm quyết định **loại bỏ biến Country** khỏi tập dữ liệu vì thông tin về quốc gia đã được thể hiện gián tiếp qua các biến khác như GDP, Schooling, Status, Population, và các chỉ số y tế.

Xử lý biến Status:

Biến Status chỉ có 2 giá trị: “Developed” (Phát triển) và “Developing” (Đang phát triển). Đây là biến phân loại nhị phân, phù hợp để mã hóa bằng phương pháp **One-Hot Encoding** với tham số `drop_first=True`.

Công thức mã hóa:

$$\text{Status_Developing} = \begin{cases} 1 & \text{nếu Status = "Developing"} \\ 0 & \text{nếu Status = "Developed"} \end{cases} \quad (2.2)$$

Lý do sử dụng drop_first=True:

- Tránh **dummy variable trap**: Khi có k loại, chỉ cần $k - 1$ biến dummy
- Tránh **multicollinearity hoàn hảo**: Nếu giữ cả 2 cột, chúng có tương quan âm hoàn hảo (-1)
- Giảm chiều dữ liệu: Từ 1 cột phân loại thành 1 cột nhị phân thay vì 2 cột

Sau bước mã hóa, biến Status được thay thế bởi biến **Status_Developing** với giá trị 0 (Developed) hoặc 1 (Developing).

Kết quả sau tiền xử lý:

- Kích thước dữ liệu: **2938 hàng $\times$ 21 cột**
- Tổng số features: **20** (không tính target)
- Các biến đã được chuyển đổi sang dạng số, sẵn sàng cho các bước tiếp theo

2.4 Chuẩn hóa dữ liệu

Chuẩn hóa (Standardization) là một bước quan trọng trong tiền xử lý dữ liệu, đặc biệt với các mô hình học máy nhạy cảm với thang đo như SVM, KNN, Logistic Regression, và các phương pháp giảm chiều như PCA.

Tại sao cần chuẩn hóa?

Các biến trong bộ dữ liệu có đơn vị đo và phạm vi giá trị rất khác nhau:

- GDP: từ vài chục USD đến hàng chục nghìn USD
- Population: từ vài nghìn đến hàng tỷ người
- Tỷ lệ tiêm chủng: từ 0% đến 100%
- BMI: từ 10 đến 80

Nếu không chuẩn hóa, các biến có giá trị lớn sẽ chi phối quá trình học, trong khi các biến có giá trị nhỏ bị “lấn át”.

Phương pháp StandardScaler:

Nhóm sử dụng `StandardScaler` từ `scikit-learn` để chuẩn hóa dữ liệu theo phân phối chuẩn (normal distribution) với trung bình $\mu = 0$ và độ lệch chuẩn $\sigma = 1$.

Công thức chuẩn hóa:

$$x_{scaled} = \frac{x - \mu}{\sigma} \quad (2.3)$$

Trong đó:

- x là giá trị gốc

- μ là trung bình của feature: $\mu = \frac{1}{N} \sum_{i=1}^N x_i$
- σ là độ lệch chuẩn: $\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$

Quy trình thực hiện:

- Chia dữ liệu:** Trước khi chuẩn hóa, dữ liệu được chia thành tập huấn luyện (70%) và tập kiểm tra (30%) với `train_test_split`, sử dụng `random_state=42` để đảm bảo tính tái lập.
- Fit trên tập huấn luyện:** `StandardScaler` được fit (học tham số μ và σ) trên tập `X_train` để tránh **data leakage** (rò rỉ thông tin từ tập test).
- Transform cả hai tập:** Áp dụng phép biến đổi với cùng tham số đã học cho cả `X_train` và `X_test`.

Kết quả sau chuẩn hóa:

```
1 X_train_scaled: mean = -0.000000, std = 1.000000
2 X_test_scaled: mean ~ 0, std ~ 1
```

Dữ liệu đã được chuẩn hóa thành công, với các giá trị tập trung quanh 0 và độ phân tán đồng nhất. Điều này đảm bảo:

- Các feature có trọng số tương đương trong quá trình học
- Thuật toán hội tụ nhanh hơn
- Kết quả ổn định và đáng tin cậy hơn

Chương 3

Giảm chiều và trực quan hóa dữ liệu

3.1 Phân tích thành phần chính (PCA)

3.1.1 Mục đích

Phân tích thành phần chính (PCA) là phương pháp giảm chiều không giám sát, nhằm loại bỏ dư thừa và giữ lại các thành phần mang nhiều thông tin nhất. PCA biến đổi dữ liệu sang không gian mới với các trục tọa độ ít tương quan, giúp giảm chi phí tính toán, cải thiện hiệu suất mô hình và hỗ trợ trực quan hóa trong các bài toán dữ liệu có số chiều lớn.

Trong bài toán dự đoán tuổi thọ trung bình, PCA giúp:

- Giảm từ 20 đặc trưng xuống còn **15 thành phần chính** mà vẫn giữ **96.55% phương sai**.
- Loại bỏ đa cộng tuyến giữa các yếu tố như `Schooling` và `Income composition`.
- Trực quan hóa mối quan hệ giữa các chỉ số y tế - xã hội và tuổi thọ.

3.1.2 Cơ sở lý thuyết

Giả sử hệ cơ sở trực chuẩn mới là $\mathbf{U}$ và ta muốn giữ lại K tọa độ trong hệ cơ sở mới. Không mất tính tổng quát, giả sử đó là K thành phần đầu tiên.

$$\begin{array}{c} \begin{array}{|c|} \hline N \\ \hline \end{array} \\ \begin{array}{|c|} \hline D \\ \hline \end{array} \end{array} \mathbf{X} = \begin{array}{|c|} \hline K \\ \hline \end{array} \mathbf{U}_K \begin{array}{|c|} \hline D-K \\ \hline \end{array} \times \begin{array}{|c|} \hline N \\ \hline \end{array} \mathbf{Z} \begin{array}{|c|} \hline D-K \\ \hline \end{array} \mathbf{Y}$$

Original data An orthogonal matrix Coordinates in new basis

$$= \begin{array}{|c|} \hline K \\ \hline \end{array} \mathbf{U}_K \times \begin{array}{|c|} \hline N \\ \hline \end{array} \mathbf{Z} \begin{array}{|c|} \hline D \\ \hline \end{array} + \begin{array}{|c|} \hline D-K \\ \hline \end{array} \mathbf{U}_K \times \begin{array}{|c|} \hline Y \\ \hline \end{array}$$

Trong hình minh họa, hệ cơ sở mới $\mathbf{U} = [\mathbf{U}_k, \bar{\mathbf{U}}_k]$ là hệ trực chuẩn với $\mathbf{U}_k$ là ma trận con tạo bởi k cột đầu

tiên của $\mathbf{U}$.

Mục đích của PCA là tìm ma trận trực giao $\mathbf{U}$ sao cho phần lớn thông tin được giữ lại ở phần $\mathbf{U}_k \mathbf{Z}$ (phần màu xanh) và có thể lược bỏ phần $\bar{\mathbf{U}}_k \mathbf{Y}$ (phần màu đỏ) và thay bằng một ma trận không phụ thuộc vào điểm dữ liệu.

3.1.3 Các bước thực hiện

a) **Tính vector kỳ vọng của toàn bộ dữ liệu:**

$$\bar{\mathbf{x}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n$$

Trong đó $N = 2938$ là số lượng mẫu, và $\mathbf{x}_n$ là vector dữ liệu thứ n .

b) **Tính dữ liệu chuẩn hóa $\hat{\mathbf{x}}_n$:**

$$\hat{\mathbf{x}}_n = \mathbf{x}_n - \bar{\mathbf{x}}, \quad n = 1, 2, \dots, N.$$

c) **Tính ma trận hiệp phương sai:**

$$\mathbf{S} = \frac{1}{N} \hat{\mathbf{X}} \hat{\mathbf{X}}^T$$

Trong đó $\hat{\mathbf{X}}$ là ma trận dữ liệu đã được chuẩn hóa (sử dụng `StandardScaler`).

d) **Tính các trị riêng λ_i và vector riêng $\mathbf{u}_i$ của ma trận hiệp phương sai.**

e) **Chọn k giá trị riêng lớn nhất và k vector riêng tương ứng để xây dựng ma trận $\mathbf{U}_k$.**

Trong bài toán này: $k = 15$ (để giữ $\geq 95\%$ phương sai).

f) **Các cột của $\{\mathbf{u}_j\}_{j=1}^k$ là hệ cơ sở trực chuẩn.**

g) **Chiếu dữ liệu ban đầu đã chuẩn hóa $\hat{\mathbf{X}}$ xuống không gian con mới:**


$$\mathbf{Z} = \mathbf{U}_k^T \hat{\mathbf{X}}.$$

Ma trận $\mathbf{Z}$ chứa các biểu diễn nén của dữ liệu trên không gian có số chiều thấp hơn.

Dữ liệu ban đầu có thể được xấp xỉ lại từ dữ liệu nén như sau:

$$\mathbf{x} \approx \mathbf{U}_k \mathbf{Z} + \bar{\mathbf{x}}.$$


Trong đó $\mathbf{U}_k \mathbf{Z}$ là phần thông tin giữ lại và $\bar{\mathbf{x}}$ là trung bình của dữ liệu ban đầu được cộng lại để khôi phục vị trí gốc.



3.1.4 Kết quả thực nghiệm

- Số chiều gốc: 20 features (sau tiền xử lý).
- Số chiều sau PCA: 15 thành phần chính.
- Phương sai giải thích trên tập kiểm tra: 96.55%.
- Đánh giá tái tạo dữ liệu:


explained_variance_score = 0.9655



Hình 3.1: Phân tán dữ liệu theo 2 thành phần chính đầu tiên (PC1 vs PC2).

Nhận xét từ hình 3.1:


- **Gradient rõ rệt:** Từ tím (tuổi thọ thấp) → vàng (tuổi thọ cao).
- **PC1:** Đại diện cho mức độ phát triển (giáo dục, thu nhập, y tế).
- **PC2:** Liên quan đến BMI, tiêm chủng (Polio, Diphtheria).



Hình 3.2: Biểu đồ phân tán cho 6 cặp thành phần chính đầu tiên.

Nhận xét từ hình 3.2:

- **PC1 vs PC2:** Phân tách tốt nhất theo tuổi thọ.
- **PC1 vs PC3, PC1 vs PC5:** Vẫn có xu hướng, nhưng chồng lấn ở vùng trung bình.
- **PC3 vs PC4:** Phân bố ngẫu nhiên → đóng góp thấp.



Hình 3.3: Tương quan giữa các thành phần chính (PC1–PC15) và đặc trưng gốc.

PC1 (thành phần quan trọng nhất) có tương quan mạnh với:

- **Dương:** Schooling, Income composition, BMI

- **Âm:** Adult Mortality, HIV/AIDS, Status_Developing

→ PC1 đại diện cho **chỉ số phát triển con người và y tế công cộng**.

3.2 Lựa chọn đặc trưng với SelectKBest

3.2.1 Giới thiệu về SelectKBest

SelectKBest là một phương pháp feature selection (lựa chọn đặc trưng) thuộc loại supervised learning, có nghĩa là nó sử dụng thông tin từ biến mục tiêu (target) để đánh giá và chọn ra K features quan trọng nhất.

Ưu điểm:

- Giữ nguyên ý nghĩa của các features gốc (dễ diễn giải)
- Giảm số chiều dữ liệu, tránh overfitting
- Loại bỏ các features không có ý nghĩa thống kê
- Tăng tốc độ training model

Nhược điểm:

- Không xử lý multicollinearity (tương quan cao giữa các features)
- Đánh giá từng feature độc lập (không xem xét tương tác giữa các features)

3.2.2 Phương pháp f_regression

f_regression là hàm tính toán F-statistic giữa mỗi feature và target trong bài toán regression.

Công thức F-statistic:

$$F = \frac{MSR}{MSE} = \frac{SSR/1}{SSE/(n-2)} \quad (3.1)$$

Trong đó:

- SSR (Sum of Squares Regression): Tổng bình phương do hồi quy: $SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$
- SSE (Sum of Squares Error): Tổng bình phương sai số: $SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$
- MSR (Mean Square Regression): Trung bình bình phương hồi quy: $MSR = SSR / 1$
- MSE (Mean Square Error): Trung bình bình phương sai số: $MSE = SSE / (n - 2)$
- n : Số mẫu dữ liệu
- y_i : Giá trị thực tế của target
- $\hat{y}_i$: Giá trị dự đoán của target
- $\bar{y}$: Giá trị trung bình của target

Ý nghĩa:

- F-statistic cao → Feature có mối quan hệ tuyến tính mạnh với target

- F-statistic thấp → Feature ít ảnh hưởng đến target

3.2.3 Kết quả thực nghiệm

Top 10 features quan trọng nhất theo F-statistic:

Thứ hạng	Feature	F-Score
1	Schooling	2186.35
2	Income composition of resources	1953.29
3	Adult Mortality	1936.17
4	HIV/AIDS	935.39
5	BMI	926.69
6	Status_Developing	613.14
7	thinness 5-9 years	596.04
8	thinness 1-19 years	590.59
9	Diphtheria	556.06
10	Polio	496.10

Bảng 3.1: Top 10 features quan trọng nhất

Nhận xét:

- **Schooling** (số năm học trung bình) là yếu tố quan trọng nhất, với F-score = 2186.35
- **Income composition of resources** và **Adult Mortality** cũng có ảnh hưởng rất lớn
- Các yếu tố y tế như HIV/AIDS, BMI, tỷ lệ tiêm chủng cũng đóng vai trò quan trọng
- Trạng thái phát triển (Developed/Developing) có ảnh hưởng đáng kể

Kích thước dữ liệu sau khi chọn K=10 features:

- X_train_kbest shape: (2056, 10)
- X_test_kbest shape: (882, 10)

3.3 So sánh PCA và SelectKBest

Bảng tổng hợp so sánh chi tiết giữa hai phương pháp:

Đặc điểm	PCA	SelectKBest
Loại phương pháp	Tuyến tính, unsupervised	Supervised
Mục đích chính	Giảm chiều cho modeling	Chọn features quan trọng
Số chiều đầu ra	15	10
Phương sai giải thích	96.55%	N/A
Transform dữ liệu mới	Có	Có
Giải thích được	Thấp	Cao
Bảo toàn ý nghĩa	Không	Có
Xử lý multicollinearity	Có	Không
Độ phức tạp	$O(d^2 \cdot N + d^3)$	$O(d \cdot N)$

Bảng 3.2: So sánh PCA và SelectKBest

Kết quả thực nghiệm:

- **PCA (15 components):** Giảm từ 20 xuống 15 chiều, giữ 96.55% phương sai
- **SelectKBest (10 features):** Giảm từ 20 xuống 10 chiều, giữ nguyên ý nghĩa features gốc

Kết luận:

Trong dự án này, nhóm sử dụng **cả hai phương pháp** để so sánh hiệu quả:

- **PCA** để giảm chiều và loại bỏ multicollinearity
- **SelectKBest** để chọn features quan trọng nhất, dễ diễn giải

Chương 4

Phương pháp hồi quy sử dụng KNN

4.1 Giới thiệu

K-nearest neighbor là một trong những thuật toán supervised-learning đơn giản nhất trong Machine Learning. Khi training, thuật toán này không học một điều gì từ dữ liệu huấn luyện, mọi tính toán được thực hiện khi nó cần dự đoán kết quả của dữ liệu mới. Knearest neighbor có thể áp dụng được vào cả hai loại của bài toán Supervised learning là Classification và Regression.



Hình 4.1: Minh họa thuật toán K-Nearest Neighbor.

4.2 Cách thuật toán KNN hoạt động trong bài toán hồi quy

Thuật toán **K-Nearest Neighbors Regression (KNN Regression)** là một phương pháp hồi quy phi tham số (*non-parametric regression*), nghĩa là nó không giả định trước dạng hàm quan hệ giữa đầu vào x và đầu ra y . Thay vào đó, dự đoán đầu ra của một điểm mới được thực hiện dựa trên sự tương đồng (về khoảng cách) với các điểm đã biết trong tập dữ liệu huấn luyện.

4.2.1 Ý tưởng tổng quát

Giả sử ta có tập dữ liệu huấn luyện:

$$\mathcal{D} = \{(x^{(i)}, y^{(i)}) \mid i = 1, 2, \dots, N\}, \quad x^{(i)} \in \mathbb{R}^d, \quad y^{(i)} \in \mathbb{R}.$$

Khi cần dự đoán giá trị $\hat{y}$ cho một điểm mới x , thuật toán KNN sẽ thực hiện các bước:

- Tính khoảng cách giữa x và mọi điểm $x^{(i)}$ trong tập huấn luyện.
- Chọn ra k điểm có khoảng cách nhỏ nhất — gọi là **k hàng xóm gần nhất**.
- Dự đoán giá trị $\hat{y}$ bằng cách lấy trung bình (hoặc trung bình có trọng số) các giá trị $y^{(i)}$ tương ứng với k hàng xóm đó.

4.2.2 Tính khoảng cách giữa các điểm

Trong thuật toán KNN, việc đo lường **khoảng cách** giữa điểm cần dự đoán x và các điểm dữ liệu huấn luyện $x^{(i)}$ là bước quan trọng để xác định các *láng giềng gần nhất*.

(a) Trường hợp dữ liệu một chiều: Khi dữ liệu chỉ có một thuộc tính ($d = 1$), khoảng cách giữa hai điểm x và $x^{(i)}$ được tính đơn giản như sau:

$$d(x, x^{(i)}) = |x - x^{(i)}|.$$

Khoảng cách này thể hiện độ chênh lệch tuyệt đối giữa hai giá trị trên trục số.

(b) Trường hợp dữ liệu nhiều chiều: Khi dữ liệu có nhiều thuộc tính ($d > 1$), ta cần sử dụng các công thức đo khoảng cách tổng quát hơn. Khoảng cách phổ biến nhất là **khoảng cách Euclid (Euclidean distance)**:

$$d(x, x^{(i)}) = \sqrt{\sum_{j=1}^d (x_j - x_j^{(i)})^2}.$$

Ngoài ra, có thể sử dụng các biến thể khác:

$$\text{Manhattan: } d_1(x, x^{(i)}) = \sum_{j=1}^d |x_j - x_j^{(i)}|, \quad \text{Minkowski: } d_p(x, x^{(i)}) = \left(\sum_{j=1}^d |x_j - x_j^{(i)}|^p \right)^{1/p}.$$

Trong đó:

- d là số chiều của dữ liệu (số thuộc tính).
- x_j và $x_j^{(i)}$ là giá trị của thuộc tính thứ j của điểm x và $x^{(i)}$.
- p là tham số điều chỉnh độ nhạy của khoảng cách Minkowski (khi $p = 2$ thì là Euclid, khi $p = 1$ thì là Manhattan).

4.2.3 Chuẩn hóa dữ liệu (Feature Scaling)

Vì mỗi đặc trưng x_j có thể nằm trên thang đo khác nhau (ví dụ: GDP có thể hàng nghìn, BMI chỉ vài chục), việc chuẩn hóa là cần thiết để đảm bảo mọi đặc trưng có ảnh hưởng công bằng trong tính toán khoảng cách. Hai cách phổ biến:

$$z = \frac{x - \mu}{\sigma} \quad (\text{StandardScaler}), \quad z = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (\text{MinMaxScaler}).$$

4.2.4 Cách tính giá trị dự đoán

Giả sử $N_k(x)$ là tập chỉ số của k hàng xóm gần nhất của x .

(a) Trung bình đều (Uniform weights):

$$\hat{y}(x) = \frac{1}{k} \sum_{i \in N_k(x)} y^{(i)}.$$

(b) Trung bình có trọng số theo khoảng cách (Distance-weighted):

$$\hat{y}(x) = \frac{\sum_{i \in N_k(x)} w_i y^{(i)}}{\sum_{i \in N_k(x)} w_i}, \quad \text{với } w_i = \frac{1}{d(x, x^{(i)}) + \varepsilon},$$

trong đó ε là hằng số nhỏ để tránh chia cho 0.

4.2.5 Quy trình thuật toán (pseudocode)

Algorithm 1 Thuật toán KNN Regression

Require: Tập huấn luyện $\mathcal{D}$, số hàng xóm k , điểm cần dự đoán x , loại khoảng cách $d(\cdot, \cdot)$

Ensure: Giá trị dự đoán $\hat{y}(x)$

- 1: Tính $d_i = d(x, x^{(i)})$ với mọi $i = 1, \dots, N$
 - 2: Sắp xếp các d_i tăng dần và lấy k hàng xóm gần nhất $N_k(x)$
 - 3: $\hat{y}(x) = \frac{1}{k} \sum_{i \in N_k(x)} y^{(i)}$
 - 4: **return** $\hat{y}(x)$
-

4.2.6 Chọn giá trị k phù hợp

- Nếu k nhỏ $\Rightarrow$ mô hình phản ứng nhanh nhưng dễ bị nhiễu (overfitting).
- Nếu k lớn $\Rightarrow$ mô hình mượt hơn nhưng có thể làm mất chi tiết (underfitting).
- Có thể dùng *cross-validation* để chọn k tối ưu bằng cách thử nhiều giá trị k và chọn sai số nhỏ nhất.
- Trong bài toán dự đoán ta sử dụng $k = \sqrt{n}$

4.2.7 Đánh giá hiệu quả mô hình

Sử dụng các chỉ số đánh giá:

$$\text{MAE} = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|, \quad \text{MSE} = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2, \quad R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}.$$

4.2.8 Tóm tắt

KNN Regression dựa trên giả định:

“Các điểm có đặc trưng giống nhau thì giá trị đầu ra cũng gần nhau.”

Mô hình không cần huấn luyện phức tạp, chỉ cần lưu trữ dữ liệu và tính khoảng cách khi dự đoán. Nhược điểm là chi phí tính toán cao khi dữ liệu lớn.

4.3 Phương pháp KNN với bài toán hồi quy dự đoán tuổi thọ trung bình

4.3.1 Đánh giá hiệu suất mô hình theo các tỉ lệ chia dữ liệu

Để đánh giá hiệu suất của mô hình KNN Regression trong bài toán dự đoán *tuổi thọ trung bình*, ta tiến hành thử nghiệm với ba tỉ lệ chia tập dữ liệu huấn luyện và kiểm định: **80:20**, **70:30** và **60:40**. Ba dạng dữ liệu được sử dụng gồm:

- **Dữ liệu gốc:** Toàn bộ các đặc trưng sau khi chuẩn hoá.
- **Dữ liệu PCA:** Dữ liệu sau khi giảm chiều bằng phương pháp *Principal Component Analysis*.
- **Dữ liệu SelectKBest:** Dữ liệu sau khi chọn ra các đặc trưng quan trọng nhất bằng *SelectKBest*.

4.3.2 Kết quả thực nghiệm

Tỉ lệ	Dữ liệu	Train R^2	Test R^2	ΔR^2	Train MSE	Test MSE	RMSE
80:20 (4:1)	Gốc	0.8982	0.8758	0.0224	8.9641	12.3597	3.5156
70:30 (7:3)	Gốc	0.8967	0.8718	0.0249	9.0967	12.2710	3.5030
60:40 (6:4)	Gốc	0.8963	0.8770	0.0193	9.2961	11.2456	3.3535
80:20 (4:1)	PCA	0.8531	0.8348	0.0183	12.9346	16.4362	4.0542
70:30 (7:3)	PCA	0.8514	0.8306	0.0208	13.0837	16.2091	4.0260
60:40 (6:4)	PCA	0.8470	0.8325	0.0145	13.7199	15.3172	3.9137
80:20 (4:1)	SelectKBest	0.8995	0.8832	0.0162	8.8528	11.6199	3.4088
70:30 (7:3)	SelectKBest	0.8986	0.8820	0.0166	8.9228	11.2931	3.3605
60:40 (6:4)	SelectKBest	0.8976	0.8860	0.0116	9.1787	10.4247	3.2287

Bảng 4.1: So sánh kết quả huấn luyện và kiểm thử của ba phương pháp (dữ liệu gốc, PCA, và SelectKBest) theo các tỉ lệ chia dữ liệu khác nhau.

4.3.3 Phân tích kết quả


Kết quả cho thấy mô hình KNN hoạt động ổn định trên tất cả các tỉ lệ chia dữ liệu. Giá trị R^2 trên tập kiểm định dao động trong khoảng **0.83–0.89**, thể hiện khả năng dự đoán khá tốt và ổn định.

(1) So sánh giữa các loại dữ liệu:


- **Dữ liệu gốc:** Cho kết quả khá tốt, R_{test}^2 cao nhất đạt 0.877 ở tỉ lệ 60:40. Tuy nhiên, độ chênh ΔR^2 dao động quanh 0.02–0.025, cho thấy mô hình vẫn có xu hướng hơi khớp quá nhẹ.
- **Dữ liệu PCA:** Có R_{test}^2 thấp hơn so với hai dạng còn lại (tối đa 0.8348), cho thấy việc giảm chiều bằng PCA làm mất mát một phần thông tin quan trọng.
- **Dữ liệu SelectKBest:** Cho hiệu quả tốt nhất. R_{test}^2 cao nhất đạt **0.886**, MSE thấp nhất chỉ **10.4247**, và ΔR^2 nhỏ nhất **0.0116**, thể hiện khả năng học và tổng quát hoá cân bằng nhất.

(2) **Ảnh hưởng của tỉ lệ chia dữ liệu:** Khi giảm tỉ lệ train (từ 80:20 xuống 60:40), R_{test}^2 hầu như không giảm mà có xu hướng tăng nhẹ (đặc biệt ở SelectKBest). Điều này cho thấy tập dữ liệu đủ lớn và mô hình KNN có tính ổn định cao. Sự thay đổi nhỏ trong R_{test}^2 (< 0.01) chứng minh khả năng tổng quát tốt của mô hình.

(3) **Độ chênh lệch ΔR^2 và hiện tượng overfitting:** Giá trị $\Delta R^2 = |R_{train}^2 - R_{test}^2|$ được sử dụng để đo độ khớp quá (overfit). Tất cả các giá trị ΔR^2 đều **dưới 0.05**, nằm dưới ngưỡng cảnh báo (đường đỏ trên hình 4.3). Điều này chứng tỏ mô hình **không bị overfitting** ở bất kỳ dạng dữ liệu nào.




Hình 4.2: So sánh giá trị R^2 trên tập kiểm định theo tỉ lệ chia dữ liệu.




Hình 4.3: So sánh độ chênh lệch ΔR^2 giữa tập huấn luyện và kiểm định.


4.3.4 Trực quan hóa phần dư



(a) Ảnh trực quan hóa phần dư (giảm chiều pca)



(b) Ảnh trực quan hóa phần dư trong trường hợp gốc



(c) Ảnh trực quan hóa phần dư trong trường hợp giảm chiều select k best

Hình 4.4: Các biểu đồ trực quan hóa phần dư

Nhận xét:

- Ta có thể thấy các giá trị *residual* phân bố ngẫu nhiên xung quanh trục giá trị 0.
- Việc lựa chọn giá trị K cho cả ba trường hợp là hợp lý, giúp mô hình dự đoán được đa số dữ liệu.
- Việc sử dụng mô hình *K-Nearest Neighbors (KNN)* là phù hợp.

4.3.5 Nhận xét tổng quan

Phương pháp KNN Regression cho thấy hiệu quả cao trong bài toán dự đoán tuổi thọ trung bình. Các kết luận chính:

- **SelectKBest** giúp cải thiện rõ rệt hiệu suất, mang lại R^2_{test} và MSE tốt nhất.
- Mô hình duy trì tính ổn định với các tỉ lệ chia khác nhau, không có dấu hiệu overfit.
- **PCA** mang lại lợi ích không nhiều cho bài toán này.

Tổng kết lại, mô hình KNN Regression kết hợp **SelectKBest** là lựa chọn phù hợp, vừa đảm bảo hiệu quả dự đoán, vừa tránh được hiện tượng khớp quá, đồng thời hoạt động ổn định trên các tỉ lệ chia dữ liệu khác nhau.

Chương 5

Phương pháp Linear Regression với bài toán hồi quy dự đoán tuổi thọ trung bình

5.1 Cách thuật toán Linear Regression hoạt động

5.1.1 Mô hình tổng quát

Thuật toán **Linear Regression (Hồi quy tuyến tính)** mô hình hóa mối quan hệ giữa biến đầu ra y (trong bài toán này là **tuổi thọ trung bình**) và các biến đầu vào $x_1, x_2, \dots, x_n$ (các yếu tố y tế - xã hội như GDP, BMI, tỷ lệ tiêm chủng, v.v.) theo dạng tuyến tính:

$$\hat{y} = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n = \mathbf{w}^T \mathbf{x} + w_0,$$

trong đó:

- $\hat{y}$: giá trị tuổi thọ trung bình dự đoán.
- $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$: vector đặc trưng đầu vào.
- $\mathbf{w} = [w_1, w_2, \dots, w_n]^T$: vector trọng số của mô hình.
- w_0 : hệ số chặn (bias term).

5.1.2 Hàm mất mát (Loss function)

Để tìm được các trọng số w_i tối ưu, ta cần giảm thiểu sai số giữa giá trị dự đoán $\hat{y}^{(i)}$ và giá trị thực tế $y^{(i)}$. Sai số này được đo bằng **hàm mất mát bình phương trung bình** (Mean Squared Error - MSE):

$$J(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \left(\hat{y}^{(i)} - y^{(i)} \right)^2 = \frac{1}{m} \sum_{i=1}^m \left(\mathbf{w}^T \mathbf{x}^{(i)} + w_0 - y^{(i)} \right)^2,$$

trong đó m là số lượng mẫu trong tập huấn luyện.

5.1.3 Quá trình huấn luyện mô hình

Mục tiêu của quá trình huấn luyện là tìm bộ tham số $\mathbf{w}$ và w_0 sao cho $J(\mathbf{w})$ đạt giá trị nhỏ nhất. Có hai cách phổ biến để thực hiện việc này:

a) **Công thức đóng (Closed-form solution):**

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y},$$

trong đó $\mathbf{X}$ là ma trận đặc trưng đầu vào, $\mathbf{y}$ là vector giá trị thực tế.

b) **Phương pháp Gradient Descent:** Cập nhật trọng số qua từng bước:

$$w_j := w_j - \alpha \frac{\partial J}{\partial w_j}, \quad \text{với} \quad \frac{\partial J}{\partial w_j} = \frac{2}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)}) x_j^{(i)},$$

trong đó α là tốc độ học (learning rate).

5.1.4 Dự đoán giá trị tuổi thọ trung bình

Sau khi huấn luyện, mô hình sử dụng các trọng số tối ưu $\mathbf{w}^*$ để dự đoán tuổi thọ trung bình cho một quốc gia mới:

$$\hat{y}_{\text{new}} = \mathbf{w}^{*T} \mathbf{x}_{\text{new}} + w_0^*.$$

5.1.5 Ưu và nhược điểm

Ưu điểm:

- Dễ hiểu, nhanh, và có thể giải thích được mối quan hệ giữa các biến.
- Thích hợp khi mối quan hệ giữa các đặc trưng và biến mục tiêu là gần tuyến tính.

Nhược điểm:

- Hiệu quả kém khi dữ liệu có quan hệ phi tuyến tính.
- Dễ bị ảnh hưởng bởi các ngoại lai (outliers).

5.2 Đánh giá hiệu suất mô hình theo các tỉ lệ chia dữ liệu

Để đánh giá hiệu suất của mô hình **Linear Regression** trong bài toán dự đoán *tuổi thọ trung bình*, ta tiến hành thử nghiệm với ba tỉ lệ chia tập dữ liệu huấn luyện và kiểm định: **80:20**, **70:30** và **60:40**. Các phép thử được thực hiện trên ba dạng dữ liệu khác nhau:

- **Dữ liệu gốc:** Toàn bộ các đặc trưng sau khi được chuẩn hoá.
- **Dữ liệu PCA:** Dữ liệu sau khi giảm chiều bằng phương pháp *Principal Component Analysis*.
- **Dữ liệu SelectKBest:** Dữ liệu sau khi chọn ra các đặc trưng quan trọng nhất bằng phương pháp *SelectKBest*.

5.2.1 Kết quả thực nghiệm

Tỉ lệ	Dữ liệu	Train R^2	Test R^2	ΔR^2	Train MSE	Test MSE
80:20	Gốc	0.8220	0.8093	0.0126	16.0669	17.2679
70:30	Gốc	0.8220	0.8126	0.0095	15.8402	17.5262
60:40	Gốc	0.8253	0.8100	0.0153	15.8734	17.0314
80:20	PCA	0.8114	0.7993	0.0121	17.0236	18.1756
70:30	PCA	0.8112	0.8031	0.0081	16.8019	18.4058
60:40	PCA	0.8149	0.7997	0.0151	16.8195	17.9531
80:20	SelectKBest	0.8062	0.7985	0.0077	17.4916	18.2484
70:30	SelectKBest	0.8057	0.8017	0.0040	17.2939	18.5390
60:40	SelectKBest	0.8090	0.7979	0.0111	17.3492	18.1168

Bảng 5.1: Kết quả so sánh hiệu suất mô hình Linear Regression theo tỉ lệ chia dữ liệu

5.2.2 Phân tích kết quả


Kết quả cho thấy mô hình Linear Regression hoạt động ổn định và nhất quán trên cả ba loại dữ liệu. Giá trị R^2 trên tập kiểm định dao động trong khoảng **0.79–0.82**, thể hiện khả năng mô hình hoá tương đối tốt của hồi quy tuyến tính trong bài toán dự đoán tuổi thọ trung bình.

(1) So sánh giữa các loại dữ liệu:


- **Dữ liệu gốc:** Cho kết quả R_{test}^2 cao nhất (đạt tới 0.8126 tại tỉ lệ 70:30), cho thấy mô hình hoạt động tốt nhất khi sử dụng toàn bộ đặc trưng ban đầu.
- **Dữ liệu PCA:** Hiệu suất giảm nhẹ (dao động quanh 0.799–0.803), cho thấy việc giảm chiều bằng PCA có thể làm mất đi một phần thông tin có ích cho mô hình tuyến tính.
- **Dữ liệu SelectKBest:** Cho kết quả ổn định nhất, với ΔR^2 nhỏ nhất chỉ **0.0040** ở tỉ lệ 70:30, thể hiện khả năng tổng quát hoá tốt nhất trong ba dạng dữ liệu.

(2) **Ảnh hưởng của tỉ lệ chia dữ liệu:** Khi tỉ lệ tập huấn luyện giảm (từ 80:20 sang 60:40), R_{test}^2 giảm nhẹ, đặc biệt ở dữ liệu PCA và SelectKBest. Tuy nhiên, mức giảm này không đáng kể ($\Delta R^2 < 0.01$), cho thấy mô hình Linear Regression có độ ổn định tốt và không quá nhạy cảm với kích thước tập huấn luyện. Hiệu suất cao nhất nhìn chung đạt được ở tỉ lệ chia **70:30**, thể hiện sự cân bằng giữa lượng dữ liệu huấn luyện và kiểm định.

(3) **Độ chênh lệch ΔR^2 và hiện tượng overfitting:** Giá trị $\Delta R^2 = |R_{train}^2 - R_{test}^2|$ được dùng để đánh giá mức độ khớp quá (overfit). Kết quả cho thấy tất cả các trường hợp đều có $\Delta R^2 < 0.05$, nằm dưới ngưỡng cảnh báo overfit (đường đỏ trên hình 5.2). Điều này chứng tỏ mô hình **Linear Regression không bị overfitting** và có khả năng tổng quát tốt trên dữ liệu kiểm định.




Hình 5.1: So sánh giá trị R^2 trên tập kiểm định theo tỉ lệ chia dữ liệu.




Hình 5.2: So sánh độ chênh lệch ΔR^2 giữa tập huấn luyện và kiểm định.


5.2.3 Trực quan hóa phần dư



(a) Ảnh trực quan hóa phần dư (giảm chiều pca)



(b) Ảnh trực quan hóa phần dư trong trường hợp gốc



(c) Ảnh trực quan hóa phần dư trong trường hợp giảm chiều select k best

Hình 5.3: Các biểu đồ trực quan hóa phần dư

Nhận xét:

- Mean residual $\approx 0 \rightarrow$ Mô hình không bị bias hệ thống.
- Phân bố residuals ngẫu nhiên quanh đường $y=0 \rightarrow$ giả định tuyến tính được thỏa mãn.
- Không có hình nón/phễu rõ ràng $\rightarrow$ phương sai đồng nhất được đảm bảo.
- Việc sử dụng mô hình Linear Regression là phù hợp.

5.3 Nhận xét tổng quan

Phương pháp **Linear Regression** cho thấy hiệu suất ổn định trong bài toán dự đoán tuổi thọ trung bình, với mức độ khớp mô hình và sai số trung bình hợp lý. Cụ thể:

- Mô hình đạt hiệu suất cao nhất ở tỉ lệ chia dữ liệu **70:30**.
- Tất cả các trường hợp đều có $\Delta R^2 < 0.05$, **không xuất hiện hiện tượng overfitting**.
- Dữ liệu gốc đạt R^2_{test} cao nhất, trong khi dữ liệu **SelectKBest** cho thấy khả năng tổng quát ổn định hơn.
- Giảm chiều bằng PCA chưa mang lại lợi ích rõ rệt so với việc chọn đặc trưng có trọng số cao.

Từ các kết quả trên, có thể kết luận rằng mô hình Linear Regression tuy đơn giản nhưng vẫn mang lại hiệu quả tốt và độ ổn định cao, phù hợp cho việc dự đoán các xu hướng tuyến tính trong dữ liệu tuổi thọ trung bình.

Chương 6

Phân cụm dữ liệu (K-MEANS & GMM)

6.1 Giới thiệu

Phân cụm (clustering) là một kỹ thuật học không giám sát (unsupervised learning) nhằm nhóm các điểm dữ liệu có đặc điểm tương tự vào cùng một nhóm (cluster) mà không cần nhãn dữ liệu từ trước. Trong phân tích tuổi thọ, việc phân cụm giúp:

- Nhận diện các nhóm quốc gia có đặc điểm y tế - kinh tế - xã hội tương đồng
- Phát hiện các mô hình và xu hướng ẩn trong dữ liệu
- Hỗ trợ chuyển đổi bài toán hồi quy sang phân loại một cách có cơ sở khoa học
- Tạo cơ sở cho việc thiết kế các chính sách y tế phù hợp với từng nhóm

Chương này sẽ áp dụng hai phương pháp phân cụm phổ biến là K-Means và Gaussian Mixture Model (GMM) để phân tích dữ liệu tuổi thọ, sau đó sử dụng kết quả phân cụm để tạo nhãn phân loại cho các mô hình học có giám sát.

6.2 Cơ sở lý thuyết

6.2.1 Thuật toán K-Means

6.2.1.1 Ý tưởng chính

K-Means là một trong những thuật toán phân cụm cơ bản và phổ biến nhất. Ý tưởng của K-Means là phân chia N điểm dữ liệu vào K cụm sao cho mỗi điểm thuộc về cụm có tâm (centroid) gần nó nhất.

6.2.1.2 Ký hiệu toán học

Giả sử có N điểm dữ liệu $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N] \in \mathbb{R}^{d \times N}$ và $K < N$ là số cụm cần phân chia. Cần tìm:

- Các tâm cụm: $\mathbf{m}_1, \mathbf{m}_2, \dots, \mathbf{m}_K \in \mathbb{R}^{d \times 1}$
- Nhãn của mỗi điểm dữ liệu: $\mathbf{y}_i = [y_{i1}, y_{i2}, \dots, y_{iK}]$

Với mỗi điểm $\mathbf{x}_i$, vector nhãn $\mathbf{y}_i$ được biểu diễn theo dạng **one-hot encoding**: nếu $\mathbf{x}_i$ thuộc cụm k thì $y_{ik} = 1$ và $y_{ij} = 0, \forall j \neq k$.

Ràng buộc:

$$y_{ik} \in \{0, 1\}, \quad \sum_{k=1}^K y_{ik} = 1 \quad (6.1)$$

6.2.1.3 Hàm mất mát

Hàm mất mát trong K-Means đo lường tổng bình phương khoảng cách từ mỗi điểm tới tâm cụm của nó:

$$\mathcal{L}(\mathbf{Y}, \mathbf{M}) = \sum_{i=1}^N \sum_{j=1}^K y_{ij} \|\mathbf{x}_i - \mathbf{m}_j\|_2^2 \quad (6.2)$$

Bài toán tối ưu:

$$\mathbf{Y}^*, \mathbf{M}^* = \underset{\mathbf{Y}, \mathbf{M}}{\text{argmin}} \sum_{i=1}^N \sum_{j=1}^K y_{ij} \|\mathbf{x}_i - \mathbf{m}_j\|_2^2 \quad (6.3)$$

Subject to: $y_{ij} \in \{0, 1\} \forall i, j; \sum_{j=1}^K y_{ij} = 1 \forall i$

6.2.1.4 Thuật toán tối ưu

Do bài toán trên thuộc loại mix-integer programming (khó tìm nghiệm tối ưu toàn cục), K-Means sử dụng phương pháp tối ưu xen kẽ (alternating optimization):

Bước 1: Cố định $\mathbf{M}$, tìm $\mathbf{Y}$

Với các tâm cụm cố định, gán mỗi điểm vào cụm có tâm gần nó nhất:

$$j^* = \underset{j}{\text{argmin}} \|\mathbf{x}_i - \mathbf{m}_j\|_2^2 \quad (6.4)$$

Bước 2: Cố định $\mathbf{Y}$, tìm $\mathbf{M}$

Với phân cụm cố định, cập nhật tâm mới bằng trung bình của các điểm trong cụm:

$$\text{Đặt } \ell(\mathbf{m}_j) = \sum_{i=1}^N y_{ij} \|\mathbf{x}_i - \mathbf{m}_j\|_2^2$$

$$\text{Đạo hàm: } \frac{\partial \ell(\mathbf{m}_j)}{\partial \mathbf{m}_j} = 2 \sum_{i=1}^N y_{ij} (\mathbf{m}_j - \mathbf{x}_i)$$

Giải phương trình đạo hàm bằng 0:

$$\mathbf{m}_j = \frac{\sum_{i=1}^N y_{ij} \mathbf{x}_i}{\sum_{i=1}^N y_{ij}} \quad (6.5)$$

Từ số là tổng các điểm trong cụm j , mẫu số là số lượng điểm trong cụm j . Vậy $\mathbf{m}_j$ là **trung bình cộng** của các điểm trong cụm j - đây là nguồn gốc của tên gọi *K-Means*.

6.2.1.5 Các bước thực hiện thuật toán K-Means

a) Khởi tạo:

- Input: Dữ liệu $\mathbf{X}$, số cụm K
- Khởi tạo K tâm cụm ban đầu ngẫu nhiên: $\mathbf{m}_1^{(0)}, \dots, \mathbf{m}_K^{(0)}$

- Đặt $t \leftarrow 0$

b) Lặp đến khi hội tụ:

a. *Bước gán nhãn (Assignment Step):*

Với mỗi điểm dữ liệu $i = 1, 2, \dots, N$:

- Tính khoảng cách từ $\mathbf{x}_i$ đến tất cả các tâm cụm
- Gán $\mathbf{x}_i$ vào cụm $j^* = \arg \min_j \|\mathbf{x}_i - \mathbf{m}_j^{(t)}\|_2^2$

b. *Bước cập nhật tâm (Update Step):*

Với mỗi cụm $j = 1, 2, \dots, K$:

- Tính tập các điểm được gán vào cụm j : $C_j = \{\mathbf{x}_i : \text{điểm } i \text{ thuộc cụm } j\}$
- Cập nhật tâm mới: $\mathbf{m}_j^{(t+1)} \leftarrow \frac{1}{|C_j|} \sum_{\mathbf{x}_i \in C_j} \mathbf{x}_i$

c. Tăng $t \leftarrow t + 1$

c) Điều kiện dừng:

- Các nhãn không thay đổi giữa hai vòng lặp liên tiếp, hoặc
- Đạt số vòng lặp tối đa

d) Output: Các tâm cụm $\mathbf{M}$ và nhãn $\mathbf{Y}$

6.2.1.6 Tính hội tụ

Thuật toán K-Means đảm bảo hội tụ sau một số hữu hạn vòng lặp vì:

- Hàm mất mát $\mathcal{L}(\mathbf{Y}, \mathbf{M})$ là số dương và bị chặn dưới
- Sau mỗi bước cập nhật, giá trị hàm mất mát giảm hoặc không đổi
- Số cách phân nhóm khác nhau là hữu hạn

Theo lý thuyết dãy số: một dãy số giảm và bị chặn dưới thì dãy đó hội tụ.

6.2.1.7 Ưu điểm và hạn chế

Ưu điểm:

- Đơn giản, dễ hiểu và dễ triển khai
- Hiệu quả tính toán cao với độ phức tạp $O(NKdT)$ (T là số vòng lặp)
- Hoạt động tốt với dữ liệu có cụm hình cầu, kích thước cân bằng

Hạn chế:

- Cần biết trước số cụm K
- Kết quả phụ thuộc vào khởi tạo ban đầu (có thể rơi vào local minimum)
- Giả định các cụm có hình dạng cầu, kích thước và mật độ tương đương
- Nhạy cảm với outliers

- Chỉ có thể gán hard assignment (mỗi điểm thuộc đúng 1 cụm)

6.2.2 Gaussian Mixture Model (GMM)

6.2.2.1 Ý tưởng chính

Khác với K-Means gán mỗi điểm vào đúng 1 cụm (hard assignment), GMM sử dụng **soft assignment**: mỗi điểm có xác suất thuộc về mỗi cụm. GMM giả định rằng dữ liệu được sinh ra từ một hỗn hợp (mixture) của K phân phối Gaussian.

6.2.2.2 Mô hình toán học

Mật độ xác suất của dữ liệu được biểu diễn:

$$p(\mathbf{x}) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \quad (6.6)$$

Trong đó:

- π_k : trọng số (prior probability) của cụm k , với $\sum_{k=1}^K \pi_k = 1, \pi_k \geq 0$
- $\boldsymbol{\mu}_k$: vector trung bình của Gaussian thứ k
- $\boldsymbol{\Sigma}_k$: ma trận hiệp phương sai của Gaussian thứ k
- $\mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$: mật độ xác suất Gaussian đa biến

Phân phối Gaussian đa biến:

$$\mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{d/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left(-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right) \quad (6.7)$$

6.2.2.3 Thuật toán Expectation-Maximization (EM)

GMM được tối ưu bằng thuật toán EM, bao gồm hai bước lặp đi lặp lại:

E-step (Expectation): Tính xác suất posterior (responsibility) của cụm k với điểm $\mathbf{x}_i$:

$$\gamma_{ik} = \frac{\pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)} \quad (6.8)$$

γ_{ik} là xác suất điểm $\mathbf{x}_i$ thuộc cụm k (soft assignment).

M-step (Maximization): Cập nhật các tham số để tối đa hóa log-likelihood:

Số lượng hiệu dụng trong cụm k :

$$N_k = \sum_{i=1}^N \gamma_{ik} \quad (6.9)$$

Cập nhật trung bình:

$$\boldsymbol{\mu}_k^{new} = \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik} \mathbf{x}_i \quad (6.10)$$

Cập nhật ma trận hiệp phương sai:

$$\Sigma_k^{new} = \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik} (\mathbf{x}_i - \boldsymbol{\mu}_k^{new})(\mathbf{x}_i - \boldsymbol{\mu}_k^{new})^T \quad (6.11)$$

Cập nhật trọng số:

$$\pi_k^{new} = \frac{N_k}{N} \quad (6.12)$$

Hàm mục tiêu: Log-likelihood cần tối đa hóa:

$$\log p(\mathbf{X}|\boldsymbol{\theta}) = \sum_{i=1}^N \log \left(\sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \Sigma_k) \right) \quad (6.13)$$

6.2.2.4 Các bước thực hiện thuật toán GMM

a) **Khởi tạo:**

- Input: Dữ liệu $\mathbf{X}$, số cụm K
- Khởi tạo ngẫu nhiên các tham số ban đầu:
 - Trọng số: $\pi_k^{(0)}$ cho $k = 1, \dots, K$
 - Trung bình: $\boldsymbol{\mu}_k^{(0)}$ cho $k = 1, \dots, K$
 - Ma trận hiệp phương sai: $\Sigma_k^{(0)}$ cho $k = 1, \dots, K$
- Đặt $t \leftarrow 0$

b) **Lặp đến khi hội tụ:**

a. *E-step (Expectation):*

Với mỗi điểm $i = 1, 2, \dots, N$ và mỗi cụm $k = 1, 2, \dots, K$:

- Tính mật độ Gaussian:

$$p_{ik} = \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k^{(t)}, \Sigma_k^{(t)})$$

- Tính responsibility (xác suất posterior):

$$\gamma_{ik}^{(t)} = \frac{\pi_k^{(t)} \cdot p_{ik}}{\sum_{j=1}^K \pi_j^{(t)} \cdot p_{ij}}$$

b. *M-step (Maximization):*

Với mỗi cụm $k = 1, 2, \dots, K$:

- Tính số lượng hiệu dụng:

$$N_k \leftarrow \sum_{i=1}^N \gamma_{ik}^{(t)}$$

- Cập nhật trung bình:

$$\boldsymbol{\mu}_k^{(t+1)} \leftarrow \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik}^{(t)} \mathbf{x}_i$$

- Cập nhật ma trận hiệp phương sai:

$$\Sigma_k^{(t+1)} \leftarrow \frac{1}{N_k} \sum_{i=1}^N \gamma_{ik}^{(t)} (\mathbf{x}_i - \boldsymbol{\mu}_k^{(t+1)})(\mathbf{x}_i - \boldsymbol{\mu}_k^{(t+1)})^T$$

- Cập nhật trọng số:

$$\pi_k^{(t+1)} \leftarrow \frac{N_k}{N}$$

c. Tăng $t \leftarrow t + 1$

c) **Điều kiện dừng:**

- Log-likelihood hội tụ (thay đổi nhỏ hơn ngưỡng), hoặc
- Đạt số vòng lặp tối đa

d) **Output:** Các tham số $\{\pi_k, \mu_k, \Sigma_k\}_{k=1}^K$

6.2.2.5 Ưu điểm và hạn chế

Ưu điểm:

- Soft assignment: cho xác suất thuộc về mỗi cụm, linh hoạt hơn K-Means
- Có thể mô hình hóa các cụm với hình dạng ellipsoid khác nhau
- Có cơ sở xác suất vững chắc
- Cung cấp ma trận hiệp phương sai cho mỗi cụm

Hạn chế:

- Phức tạp tính toán cao hơn K-Means
- Nhạy cảm với khởi tạo
- Có thể gặp vấn đề với ma trận hiệp phương sai suy biến
- Vẫn cần biết trước số cụm K

6.2.3 So sánh K-Means và GMM

Bảng 6.1: So sánh K-Means và GMM

Tiêu chí	K-Means	GMM
Phép gán cụm	Hard assignment (0 hoặc 1)	Soft assignment (xác suất)
Mô hình	Khoảng cách Euclidean	Hỗn hợp Gaussian
Hình dạng cụm	Cầu, kích thước đồng đều	Ellipsoid, linh hoạt
Độ phức tạp	$O(NKdT)$	$O(NKd^2T)$
Cơ sở lý thuyết	Heuristic	Xác suất thống kê
Khởi tạo	K-Means++	Thường dùng K-Means
Output	Nhãn cụm	Xác suất + tham số phân phối

6.3 Các độ đo đánh giá chất lượng phân cụm

6.3.1 Elbow Method (Inertia)

Định nghĩa: Inertia đo tổng bình phương khoảng cách từ mỗi điểm tới tâm cụm của nó:

$$\text{Inertia} = \sum_{i=1}^N \min_k \|\mathbf{x}_i - \mathbf{m}_k\|_2^2 \quad (6.14)$$

Nguyên tắc: Vẽ đồ thị Inertia theo K , tìm ”điểm khuỷu tay” (elbow) - điểm mà sau đó Inertia giảm chậm lại. Giá trị K tại điểm khuỷu tay là số cụm hợp lý.

Ý nghĩa: Inertia luôn giảm khi K tăng, nhưng tốc độ giảm chậm lại sau một ngưỡng nhất định.

6.3.2 Silhouette Score

Định nghĩa: Cho mỗi điểm $\mathbf{x}_i$ trong cụm C_k :

- a_i : khoảng cách trung bình từ $\mathbf{x}_i$ tới các điểm khác trong cùng cụm
- b_i : khoảng cách trung bình từ $\mathbf{x}_i$ tới các điểm trong cụm gần nhất khác

Silhouette coefficient của điểm i :

$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)} \quad (6.15)$$

Silhouette Score của toàn bộ dữ liệu:

$$\text{Silhouette Score} = \frac{1}{N} \sum_{i=1}^N s_i \quad (6.16)$$

Giá trị: $s_i \in [-1, 1]$

- s_i gần 1: điểm được phân cụm tốt
- s_i gần 0: điểm nằm ở biên giới giữa hai cụm
- s_i âm: điểm có thể bị phân cụm sai

Nguyên tắc: Chọn K có Silhouette Score cao nhất.

6.3.3 Davies-Bouldin Index

Định nghĩa: Đo mức độ tương tự giữa mỗi cụm với cụm giống nó nhất:

Khoảng cách trung bình trong cụm k :

$$S_k = \frac{1}{|C_k|} \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \mathbf{m}_k\|_2 \quad (6.17)$$

Khoảng cách giữa hai tâm cụm:

$$M_{kl} = \|\mathbf{m}_k - \mathbf{m}_l\|_2 \quad (6.18)$$

Davies-Bouldin Index:

$$DB = \frac{1}{K} \sum_{k=1}^K \max_{l \neq k} \left(\frac{S_k + S_l}{M_{kl}} \right) \quad (6.19)$$

Nguyên tắc: Giá trị DB càng **nhỏ** càng tốt (các cụm compact và tách biệt).

6.3.4 Calinski-Harabasz Index

Định nghĩa: Tỷ lệ giữa phương sai giữa các cụm và phương sai trong cụm:

Phương sai giữa các cụm (between-cluster dispersion):

$$SS_B = \sum_{k=1}^K |C_k| \|\mathbf{m}_k - \bar{\mathbf{x}}\|_2^2 \quad (6.20)$$

Phương sai trong cụm (within-cluster dispersion):

$$SS_W = \sum_{k=1}^K \sum_{\mathbf{x}_i \in C_k} \|\mathbf{x}_i - \mathbf{m}_k\|_2^2 \quad (6.21)$$

Calinski-Harabasz Index:

$$CH = \frac{SS_B}{SS_W} \times \frac{N - K}{K - 1} \quad (6.22)$$

Nguyên tắc: Giá trị CH càng **cao** càng tốt (cụm tách biệt rõ ràng).

6.3.5 BIC và AIC (cho GMM)

Bayesian Information Criterion (BIC):

$$BIC = -2 \log \mathcal{L} + p \log N \quad (6.23)$$

Akaike Information Criterion (AIC):

$$AIC = -2 \log \mathcal{L} + 2p \quad (6.24)$$

Trong đó:

- $\log \mathcal{L}$: log-likelihood của mô hình
- p : số tham số của mô hình GMM = $K(d + d(d + 1)/2 + 1) - 1$
- N : số mẫu

Nguyên tắc: BIC và AIC càng **nhỏ** càng tốt (cân bằng giữa fit và độ phức tạp).

6.3.6 ANOVA F-test

Mục đích: Kiểm định xem có sự khác biệt có ý nghĩa thống kê về biến mục tiêu (Life Expectancy) giữa các cụm hay không.

Giả thuyết:

- H_0 : Trung bình Life Expectancy của tất cả các cụm bằng nhau
- H_1 : Có ít nhất một cặp cụm có trung bình khác nhau

Thông kê F:

$$F = \frac{SS_{between}/(K - 1)}{SS_{within}/(N - K)} \quad (6.25)$$

Với:

- $SS_{between} = \sum_{k=1}^K n_k (\bar{y}_k - \bar{y})^2$: tổng bình phương giữa nhóm
- $SS_{within} = \sum_{k=1}^K \sum_{i \in C_k} (y_i - \bar{y}_k)^2$: tổng bình phương trong nhóm

Ý nghĩa: Kiểm định ANOVA được sử dụng để đánh giá mức độ khác biệt về kỳ vọng tuổi thọ giữa các cụm thu được từ quá trình phân cụm.

6.4 Thực nghiệm

6.4.1 Mô tả bộ dữ liệu

Bộ dữ liệu được sử dụng trong nghiên cứu này là *Life Expectancy Dataset*, bao gồm các thông tin về tuổi thọ trung bình và các yếu tố kinh tế - xã hội - y tế của các quốc gia trên thế giới trong nhiều năm.

Sau quá trình làm sạch dữ liệu, bộ dữ liệu cuối cùng gồm:

- $N = 2938$ mẫu quan sát (quốc gia-năm)
- $d = 20$ thuộc tính đầu vào

Biến mục tiêu ban đầu là **Life Expectancy** (tuổi thọ trung bình), là biến liên tục.

Các nhóm đặc trưng chính:

- **Y tế:** Adult Mortality, Infant Deaths, BMI, HIV/AIDS, Immunization
- **Kinh tế:** GDP, Total Expenditure
- **Xã hội:** Schooling, Population

6.4.2 Tiền xử lý dữ liệu

Trước khi thực hiện phân cụm, dữ liệu được tiền xử lý theo các bước sau:

- Xử lý giá trị thiếu bằng phương pháp thay thế trung bình theo từng quốc gia
- Loại bỏ các cột không mang ý nghĩa phân tích
- Chuẩn hóa dữ liệu bằng **StandardScaler**:

$$x' = \frac{x - \mu}{\sigma} \quad (6.26)$$

Việc chuẩn hóa giúp các đặc trưng có cùng thang đo, tránh việc các thuộc tính có giá trị lớn chi phối quá trình phân cụm.

6.4.3 Thiết lập thí nghiệm

Các thí nghiệm được thực hiện với số cụm:

$$K \in \{2, 3, 4, \dots, 10\} \quad (6.27)$$

Với mỗi giá trị K , các chỉ số đánh giá sau được tính toán:

- Inertia (Elbow Method)

- Silhouette Score
- Davies-Bouldin Index
- Calinski-Harabasz Index

Đối với GMM, thêm hai chỉ số:


- Bayesian Information Criterion (BIC)
- Akaike Information Criterion (AIC)

6.5 Kết quả và phân tích

6.5.1 Lựa chọn số cụm K

6.5.1.1 Phân tích các chỉ số đánh giá

Hình 6.1 thể hiện các chỉ số đánh giá cho K-Means và GMM với số cụm từ 2 đến 10.



Hình 6.1: Các chỉ số đánh giá cho K-Means và GMM

Elbow Method: Đồ thị Elbow cho thấy giá trị Inertia giảm mạnh khi K tăng từ 2 đến 3, sau đó tốc độ giảm chậm lại rõ rệt. Điều này cho thấy $K = 3$ là một ứng viên hợp lý.

Silhouette Score: Silhouette Score đạt giá trị cao nhất tại $K = 3$ cho cả K-Means (0.2198) và GMM (0.1529), cho thấy các cụm ở giá trị này vừa compact vừa tách biệt tốt.

Davies-Bouldin và Calinski-Harabasz:

- Davies-Bouldin Index đạt giá trị thấp tại $K = 3$ (1.4455 cho K-Means)
- Calinski-Harabasz Index đạt giá trị cao tại $K = 3$ (610.38 cho K-Means)

Kết quả với GMM: Đối với GMM, các giá trị BIC (38804.72) và AIC (34662.77) đạt giá trị phù hợp tại $K = 3$, cho thấy mô hình đạt sự cân bằng tốt giữa độ phù hợp và độ phức tạp.

Kết luận: Dựa trên các chỉ số đánh giá, số cụm tối ưu được chọn là:

$$K = 3 \quad (6.28)$$

6.5.2 Kết quả phân cụm với K=3

Bảng 6.2 thể hiện kết quả đánh giá chất lượng phân cụm cho K-Means và GMM với $K = 3$.

Bảng 6.2: Kết quả đánh giá chất lượng phân cụm với K=3

Chỉ số	K-Means	GMM
Silhouette Score	0.2198	0.0864
Davies-Bouldin Index	1.4455	2.4430
Calinski-Harabasz	610.38	382.10

6.5.3 Phân tích đặc trưng các cụm

Sau khi phân cụm với $K = 3$, dữ liệu được chia thành ba nhóm với đặc điểm được thể hiện trong Bảng 6.3 và 6.4.

Bảng 6.3: Thống kê Life Expectancy theo cụm K-Means

Cụm	Số mẫu	Mean	Std	Min	Max
0	1226	61.06	8.12	36.3	79.0
1	1692	75.23	4.85	59.2	89.0
2	20	61.93	7.37	47.1	68.3

Bảng 6.4: Thống kê Life Expectancy theo cụm GMM

Cụm	Số mẫu	Mean	Std	Min	Max
0	877	59.60	8.47	36.3	81.7
1	761	78.11	4.32	62.8	89.0
2	1300	70.52	5.88	49.2	89.0

Hình 6.2 thể hiện phân bố Life Expectancy theo các cụm.

Nhận xét:


- **Cụm 0 (K-Means) / Cụm 0 (GMM):** Tuổi thọ thấp, tỷ lệ tử vong cao, điều kiện y tế hạn chế
- **Cụm 1 (K-Means) / Cụm 2 (GMM):** Tuổi thọ trung bình, điều kiện kinh tế - y tế đang phát triển
- **Cụm 2 (K-Means) / Cụm 1 (GMM):** Tuổi thọ cao, hệ thống y tế và giáo dục phát triển

Giá trị trung bình của Life Expectancy giữa các cụm khác biệt rõ rệt, đặc biệt với GMM có sự phân bố cân bằng hơn về số lượng mẫu.


6.5.4 Trực quan hóa dữ liệu bằng PCA

Để trực quan hóa kết quả phân cụm trong không gian 2 chiều, nhóm em sử dụng PCA để giảm chiều dữ liệu từ 20 chiều xuống 2 chiều. Hình 6.3 thể hiện kết quả phân cụm trong không gian PCA.

Các tâm cụm (centroids) được đánh dấu bằng dấu X màu đỏ. Có thể thấy các cụm có sự phân tách khá rõ ràng, mặc dù có một số vùng chồng lấn giữa các cụm.



Hình 6.2: Phân bố Life Expectancy theo cụm



Hình 6.3: Trực quan hóa kết quả phân cụm bằng PCA 2D. PC1 giải thích 29.40% phương sai, PC2 giải thích 13.28% phương sai.

6.5.5 Phân tích đặc trưng của các cụm

Hình 6.4 thể hiện heatmap các đặc trưng quan trọng của từng cụm so với trung bình chung (chuẩn hóa Z-score).

Nhận xét đặc điểm các cụm (K-Means):

Cụm 0: (1226 mẫu, Life Expectancy: 61.1 ± 8.1 năm)


- Đặc điểm CAO: Adult Mortality
- Đặc điểm THẤP: BMI, Income composition of resources, Schooling
- Đây là nhóm các quốc gia có điều kiện y tế và kinh tế kém phát triển

Cụm 1: (1692 mẫu, Life Expectancy: 75.2 ± 4.8 năm)

- Đặc điểm CAO: BMI, Income composition of resources, Schooling
- Đây là nhóm các quốc gia phát triển với điều kiện sống tốt

Cụm 2: (20 mẫu, Life Expectancy: 61.9 ± 7.4 năm)

- Đặc điểm THẤP: BMI, Income composition of resources, Schooling, GDP



Hình 6.4: Heatmap: Đặc trưng các cụm so với trung bình chung (Z-score)

- Đây là nhóm nhỏ các quốc gia có đặc điểm outlier

6.5.6 Kiểm định ANOVA

Kiểm định ANOVA được sử dụng để đánh giá sự khác biệt về Life Expectancy giữa các cụm.

Kết quả cho K-Means:

- F-statistic: 1736.92
- P-value: < 0.0001 (rất nhỏ, gần bằng 0)

Kết quả cho GMM:

- F-statistic: 1726.66
- P-value: < 0.0001 (rất nhỏ, gần bằng 0)

Do $p\text{-value} < 0.05$, ta bác bỏ giả thuyết H_0 . **Kết luận:** Có sự khác biệt CÓ Ý NGHĨA THỐNG KÊ về Life Expectancy giữa các cụm. Kết quả phân cụm có ý nghĩa thống kê đối với biến Life Expectancy.

6.6 Kết luận chương

Trong chương này, nhóm em đã trình bày chi tiết các phương pháp phân cụm dữ liệu không giám sát, bao gồm K-Means và Gaussian Mixture Model (GMM), cùng với cơ sở lý thuyết, mô hình toán học và thuật toán tối ưu tương ứng.

Các điểm chính của chương bao gồm:

- Trình bày nguyên lý hoạt động và bài toán tối ưu của K-Means dựa trên khoảng cách Euclidean
- Mô hình hóa phân cụm theo xác suất với Gaussian Mixture Model và thuật toán EM
- So sánh ưu điểm và hạn chế giữa K-Means và GMM

- Giới thiệu các độ đo đánh giá chất lượng phân cụm: Elbow Method, Silhouette Score, Davies-Bouldin Index, Calinski-Harabasz Index
- Sử dụng BIC và AIC để lựa chọn số cụm tối ưu cho GMM
- Áp dụng kiểm định ANOVA để đánh giá ý nghĩa thống kê của kết quả phân cụm đối với biến mục tiêu

Kết quả chính:

- Số cụm tối ưu được xác định là $K = 3$ dựa trên tổng hợp các chỉ số đánh giá
- GMM cho kết quả phân bố cân bằng hơn K-Means (877, 1300, 761 mẫu so với 1226, 1692, 20 mẫu)
- Kiểm định ANOVA cho thấy sự khác biệt có ý nghĩa thống kê về Life Expectancy giữa các cụm ($p\text{-value} < 0.0001$)

Kết quả phân cụm trong chương này sẽ được sử dụng như một bước trung gian quan trọng nhằm tạo nhãn phân loại cho dữ liệu, từ đó phục vụ cho việc xây dựng và đánh giá các mô hình học có giám sát trong các chương tiếp theo

Chương 7

Chuyển bài toán hồi quy về phân loại

7.1 Chuẩn bị dữ liệu

7.1.1 Kết quả phân cụm

So sánh các cụm KMeans và GMM			
Cụm	Phương pháp	Mean (năm)	Số mẫu
0	KMeans	61.06	1226
1	KMeans	75.23	1692
2	KMeans	61.92	20
0	GMM	70.52	1300
1	GMM	78.11	761
2	GMM	59.60	877

Hình 7.1: So sánh các cụm Kmeans và GMM

Nhận xét:

Sau khi áp dụng hai thuật toán **KMeans** và **Gaussian Mixture Model (GMM)** với số cụm tối ưu là 3, nhóm tiến hành so sánh chất lượng phân cụm dựa trên giá trị trung bình tuổi thọ (*Life Expectancy*) và độ cân bằng số lượng mẫu giữa các cụm.

- **KMeans**: Các cụm có giá trị trung bình tuổi thọ được phân biệt khá tốt. Tuy nhiên, tồn tại sự mất cân bằng đáng kể về số lượng mẫu — một số cụm chứa quá nhiều dữ liệu trong khi cụm khác lại quá ít. Điều này có thể dẫn đến mô hình phân loại sau này bị thiên lệch (*bias*) về phía cụm có số lượng mẫu lớn hơn.
- **GMM**: Cũng phân tách được 3 mức tuổi thọ với khoảng cách trung bình giữa các cụm rõ ràng và hợp lý (thấp — trung bình — cao). Điểm nổi bật là số lượng mẫu ở mỗi cụm được phân bố khá đồng đều và cân bằng hơn so với KMeans.

Do yêu cầu của bài toán phân loại là xây dựng các lớp đầu ra có kích thước xấp xỉ nhau nhằm tránh vấn đề mất cân bằng lớp, đồng thời vẫn giữ được ý nghĩa thực tế về mức độ tuổi thọ, nhóm quyết định lựa chọn kết quả phân cụm từ GMM làm cơ sở để chuyển đổi biến mục tiêu liên tục (*Life Expectancy*) thành biến phân loại với 3 lớp.

7.1.2 Tạo nhãn phân loại

Sau khi lựa chọn kết quả phân cụm từ Gaussian Mixture Model (GMM) với 3 cụm, nhóm tiến hành xây dựng các nhãn phân loại (class labels) cho biến mục tiêu *Life Expectancy* dựa trên nguyên tắc kết hợp giữa ý nghĩa thống kê của các cụm và yêu cầu cân bằng số lượng mẫu giữa các lớp.

Quá trình được thực hiện qua 4 bước chính:

a) Phân tích các cụm GMM:

- Sắp xếp 3 cụm theo giá trị trung bình tuổi thọ tăng dần.
- Gán ý nghĩa định tính: Nhóm Thấp (cụm có mean thấp nhất), Nhóm Trung bình, Nhóm Cao (cụm có mean cao nhất).
- Kết quả:
 - Nhóm Thấp: ≈ 59.60
 - Nhóm Trung bình: ≈ 70.52
 - Nhóm Cao: ≈ 78.11

b) Tính ngưỡng gợi ý từ kết quả phân cụm:

- Tính ngưỡng phân cách lý thuyết bằng trung bình của hai mean liền kề:

$$\text{Threshold}_1 = \frac{\text{mean}_{\text{thấp}} + \text{mean}_{\text{trung bình}}}{2}, \quad \text{Threshold}_2 = \frac{\text{mean}_{\text{trung bình}} + \text{mean}_{\text{cao}}}{2}$$

- Các ngưỡng này đảm bảo giữ được khoảng cách tự nhiên giữa các cụm do GMM phát hiện.
- Kết quả:
 - Ngưỡng gợi ý 1 (Thấp/Trung bình): 65.06
 - Ngưỡng gợi ý 2 (Trung bình/Cao): 74.31

c) Tinh chỉnh ngưỡng để cân bằng số lượng mẫu:

- Mục tiêu: Mỗi lớp có khoảng $\frac{N}{3}$ mẫu (với N là tổng số quan sát).
- Thực hiện tìm kiếm cục bộ trong khoảng ± 3 năm xung quanh ngưỡng gợi ý, với bước nhảy 0.1 năm.
- Chọn ngưỡng cuối cùng sao cho số lượng mẫu ở nhóm Thấp và nhóm Trung bình gần nhất với mục tiêu.
- Kết quả ngưỡng sau tinh chỉnh:
 - Threshold 1: 66.6 (lệch 5 mẫu so với mục tiêu)

- Threshold 2: 74.4 (lệch 4 mẫu so với mục tiêu)

d) **Tạo nhãn phân loại và kiểm tra phân bố:**

- Ánh xạ giá trị *Life Expectancy* thành 3 nhãn:
 - Nhãn 0 (Thấp): Life expectancy < 66.6
 - Nhãn 1 (Trung bình): 66.6 <= Life expectancy < 74.4
 - Nhãn 2 (Cao): Life expectancy >= 74.4
- Kết quả phân bố:

Bảng 7.1: Phân bố số lượng mẫu theo nhãn phân loại cuối cùng

Nhãn	Tên nhóm	Số mẫu	Tỷ lệ (%)
0	Thấp	974	33.2%
1	Trung bình	975	33.2%
2	Cao	989	33.7%

- Có thể thấy 3 lớp có số lượng mẫu rất cân bằng, đáp ứng tốt yêu cầu tránh mất cân bằng lớp (*class imbalance*).

Phương pháp này kết hợp ưu điểm của phân cụm không giám sát (GMM phát hiện cấu trúc tự nhiên của dữ liệu) với điều chỉnh thủ công nhẹ để đạt được sự cân bằng cần thiết cho bài toán phân loại. Kết quả là một biến mục tiêu phân loại có 3 lớp rõ ràng về ý nghĩa (Thấp – Trung bình – Cao) và gần như đồng đều về số lượng mẫu.

7.2 Các mô hình phân loại

7.2.1 Mô hình Logistic Regression

7.2.1.1 Giới thiệu

Hồi quy logistic là một thuật toán học máy có giám sát được sử dụng phổ biến cho các bài toán phân loại (classification). Mục tiêu của bài toán là phân loại 3 nhãn nên nhóm tiến hành xây dựng mô hình phân loại đa lớp sử dụng **Multinomial Logistic Regression (Softmax Regression)**.

Softmax Regression là một trong những thuật toán học máy có giám sát nền tảng, được thiết kế chuyên biệt để giải quyết bài toán phân loại đa lớp. Điểm mấu chốt của thuật toán này là việc sử dụng hàm Softmax, có chức năng chuyển đổi các điểm số (logits) thô từ mô hình thành một phân bố xác suất trên tất cả các lớp. Kết quả đầu ra này cho phép chúng ta ước lượng khả năng một mẫu dữ liệu thuộc về từng lớp và đưa ra dự đoán một cách linh hoạt.

7.2.1.2 Cơ sở lý thuyết

a) Hàm Softmax

Cho đặc trưng đầu vào $\mathbf{x} \in \mathbb{R}^d$, trọng số $\mathbf{W} \in \mathbb{R}^{K \times d}$ và độ lệch $\mathbf{b} \in \mathbb{R}^K$. Vector logit được xác định

bởi $\mathbf{z} = (z_1, z_2, \dots, z_K) \in \mathbb{R}^K$, trong đó K là số lớp, $z_i = \mathbf{w}_i^T + b_i$ biểu diễn điểm số (logit) gán cho lớp thứ i

Hàm Softmax được định nghĩa như sau:

$$\text{Softmax}(\mathbf{z})_k = \frac{\exp(z_k)}{\sum_{j=1}^K \exp(z_j)}, \quad k = 1, 2, \dots, K$$

Kết quả là vector $\text{Softmax}(\mathbf{z})$ thỏa mãn các tính chất sau:

- Mỗi phần tử nằm trong khoảng mở $(0, 1)$,
- Tổng các phần tử bằng 1:

$$\sum_{k=1}^K \text{Softmax}(\mathbf{z})_k = 1$$

Do đó, đầu ra của hàm Softmax có thể được diễn giải trực tiếp như xác suất thuộc về từng lớp trong bài toán phân loại đa lớp.

b) **Overflow và Underflow khi tính Softmax**

Khi các giá trị z_k rất lớn (dương hoặc âm), việc tính toán trực tiếp hàm mũ $\exp(z_k)$ có thể gây ra hai vấn đề:

- Nếu z_k rất lớn có thể vượt quá giới hạn biểu diễn của kiểu số thực (overflow) $\rightarrow$ giá trị trở thành ∞ .
- Nếu z_k rất nhỏ gần bằng 0 (underflow) $\rightarrow$ mất độ chính xác.

Trong cả hai trường hợp, phép chia ở mẫu số có thể dẫn đến kết quả không xác định hoặc sai số lớn.

c) **Softmax-stable**

Để khắc phục vấn đề trên, ta trừ đi giá trị lớn nhất trong vector logits trước khi tính hàm mũ. Công thức ổn định được viết lại như sau:

$$\text{Softmax}(\mathbf{z})_k = \frac{\exp(z_k - c)}{\sum_{j=1}^K \exp(z_j - c)}, \quad \text{với } c = \max_{j=1, \dots, K} \{z_j\}$$

Việc trừ đi hằng số c có các ưu điểm:

- Giá trị lớn nhất trong tử số là $\exp(0) = 1$, các giá trị còn lại ≤ 1 ,
- Không có giá trị nào bị overflow,
- Kết quả cuối cùng không thay đổi vì hằng số c xuất hiện đồng thời ở tử và mẫu:

$$\frac{\exp(z_k - c)}{\sum_j \exp(z_j - c)} = \frac{\exp(z_k) \cdot \exp(-c)}{\exp(-c) \cdot \sum_j \exp(z_j)} = \frac{\exp(z_k)}{\sum_j \exp(z_j)}$$

d) **Chuyển đổi logit thành xác suất**

$$P(y_i = k \mid \mathbf{x}_i) = \frac{\exp(z_{ik} - c)}{\sum_{j=1}^K \exp(z_{ij} - c)}, \quad k = 1, 2, \dots, K$$

Hàm này đảm bảo:

- $0 < P(y_i = k | \mathbf{x}_i) < 1$ với mọi k ,
- $\sum_{k=1}^K P(y_i = k | \mathbf{x}_i) = 1$.

e) **Hàm mất mát Cross-Entropy**

Mô hình được huấn luyện bằng cách cực tiểu hóa hàm mất mát Cross-Entropy (tương đương cực đại hóa log-likelihood):

$$J(\mathbf{W}) = - \sum_{j=1}^K y_{ij} \log(\hat{y}_{ij})$$

trong đó:

- K là số lượng lớp trong bài toán phân loại,
- $\mathbf{y}_i = (y_{i1}, y_{i2}, \dots, y_{iK}) \in \{0, 1\}^K$ là vector one-hot encoding của nhãn thực tế của mẫu i ,
- $y_{ij} = 1$ nếu mẫu thứ i thuộc lớp j , và $y_{ij} = 0$ nếu ngược lại,
- $\hat{y}_{ij} = P(y_i = j | x_i)$ là xác suất dự đoán (sau khi qua hàm softmax) rằng mẫu i thuộc lớp j ,
- $\hat{\mathbf{y}}_i = (\hat{y}_{i1}, \hat{y}_{i2}, \dots, \hat{y}_{iK})$ là vector xác suất dự đoán.

f) **Tối ưu hàm mất mát**

Để cực tiểu hóa $J(\mathbf{W})$, sử dụng thuật toán Stochastic Gradient Descent (SGD).

Algorithm 2 Stochastic Gradient Descent

Require: Tập dữ liệu huấn luyện $\{(x_n, y_n)\}_{n=1}^N$, hàm mất mát $J(\theta)$

- 1: **Đầu vào:** Tốc độ học $\eta > 0$; Khởi tạo tham số $w \in \mathbb{R}^{d \times K}$ bất kỳ ở bước $t = 0$
- 2: Tráo dữ liệu ngẫu nhiên thứ tự các cặp dữ liệu (x_n, y_n) . Lặp lại với $n = 1, 2, \dots, N$ thực hiện:
- 3: Tính gradient theo công thức:

$$\nabla_w J_n(w)$$

- 4: Cập nhật tham số:

$$w \leftarrow w - \eta \cdot \frac{\partial J_n(w)}{\partial w}$$

- 5: Nếu đạt điều kiện dừng, kết thúc. Ngược lại quay lại bước 2.
-

7.2.1.3 Kết quả và đánh giá

Để đánh giá hiệu suất của mô hình Softmax Regression trong bài toán phân loại tuổi thọ trung bình, ta tiến hành thử nghiệm với ba tỉ lệ chia tập dữ liệu huấn luyện và kiểm định: 80:20, 70:30 và 60:40. Hai dạng dữ liệu được sử dụng gồm:

- **Dữ liệu gốc:** Toàn bộ các đặc trưng sau khi phân cụm và chuẩn hóa.
- **Dữ liệu PCA:** Dữ liệu sau khi giảm còn 1/3 số chiều bằng phương pháp *Principal Component Analysis*.


(a) **Kết quả thực nghiệm**

Tỉ lệ chia	Loại dữ liệu	Mô hình	Accuracy (Train)	Accuracy (Test)	Chênh accuracy
4:1 (80/20)	Dữ liệu gốc	Logistic Regression	0.8191	0.7874	0.0317
7:3 (70/30)	Dữ liệu gốc	Logistic Regression	0.8249	0.8005	0.0244
6:4 (60/40)	Dữ liệu gốc	Logistic Regression	0.8309	0.7917	0.0392
7:3 (70/30)	Sau PCA (1/3 chiều)	Logistic Regression	0.7860	0.7540	0.0320
6:4 (60/40)	Sau PCA (1/3 chiều)	Logistic Regression	0.7911	0.7611	0.0301
4:1 (80/20)	Sau PCA (1/3 chiều)	Logistic Regression	0.7877	0.7415	0.0462

Bảng 7.2: So sánh hiệu suất mô hình Logistic Regression theo tỉ lệ chia dữ liệu và loại dữ liệu


(b) Phân tích kết quả

1. So sánh giữa các loại dữ liệu




Hình 7.2: So sánh Accuracy (Test) của Logistic Regression giữa dữ liệu gốc và dữ liệu sau PCA

- Trong tất cả các tỷ lệ chia dữ liệu (4:1, 7:3, 6:4), mô hình Logistic Regression trên dữ liệu gốc luôn đạt Test Accuracy cao hơn so với dữ liệu đã giảm chiều bằng PCA (xuống còn 1/3 số chiều ban đầu)
- Mức giảm trung bình khoảng 4–5% Test Accuracy sau khi áp dụng PCA. Sự chênh lệch này cho thấy việc giảm chiều bằng PCA đã làm mất một phần thông tin quan trọng cần thiết cho bài toán phân loại, dẫn đến hiệu suất dự đoán trên tập test giảm rõ rệt



Hình 7.3: Confusion matrix của mô hình Logistic Regression tại tỉ lệ chia 7:3 (dữ liệu gốc)

Ma trận nhầm lẫn tại tỉ lệ 7:3 của dữ liệu gốc cho ta thấy giá trị trên đường chéo chính chiếm tỷ trọng lớn, cho thấy mô hình dự đoán đúng phần lớn các mẫu thuộc từng lớp, phản ánh khả năng phân loại tương đối tốt. Tuy nhiên mô hình gặp khó khăn trong việc phân biệt giữa lớp 1 và lớp 2 (hai lớp này có sự tương đồng cao về đặc trưng). Lớp 0 là lớp "dễ" nhất, gần như không bị nhầm với lớp 2




Hình 7.4: Confusion matrix của mô hình Logistic Regression tại tỉ lệ chia 7:3 (dữ liệu giảm chiều pca)

Việc giảm chiều xuống chỉ còn 1/3 số chiều bằng PCA làm suy giảm rõ rệt khả năng phân loại, đặc biệt ở các lớp có sự tương đồng cao (lớp 1 ↔ lớp 2). Tuy nhiên lớp 0 vẫn ổn định tương đối → cho thấy lớp này có đặc trưng rất nổi bật (phương sai lớn, dễ được PCA giữ lại)

2. Ảnh hưởng của tỉ lệ chia dữ liệu

Tỷ lệ 70/30 cân bằng tốt nhất. Vì Logistic Regression ít tham số và dễ tổng quát hóa, nó tận dụng tốt khi có lượng Train vừa đủ (không quá nhiều để tránh học nhiễu, không quá ít để tránh underfit)

3. Độ chênh lệch Accuracy (Train–Test) và hiện tượng overfitting



Hình 7.5: Chênh lệch Accuracy giữa tập Train và Test của mô hình Logistic Regression

Tất cả các giá trị độ chênh đều nằm dưới ngưỡng 0.05 (đường đỏ đứt nét) → Không có hiện tượng overfitting nghiêm trọng. Tuy nhiên sau giảm chiều có dấu hiệu overfit nhẹ điều này cho thấy:

- PCA làm mất thông tin phân biệt lớp → mô hình dễ học thuộc trên train (dù train nhiều) nhưng không tổng quát tốt trên test
- Dữ liệu sau giảm chiều trở nên quá đơn giản → Logistic Regression bắt đầu có xu hướng overfit khi được cung cấp nhiều mẫu train

(c) Tại sao cho kết quả như vậy

1. Tại sao dữ liệu gốc tốt hơn PCA

- PCA là thuật toán Unsupervised: PCA hoạt động dựa trên phương sai (variance) – nó giữ lại các chiều có sự biến động dữ liệu lớn nhất mà không hề biết chiều nào chứa thông tin giúp phân loại nhãn.
- Giảm chiều quá đà: Việc giảm xuống chỉ còn 1/3 số chiều là một mức cắt giảm rất mạnh. Do dữ liệu gốc không quá dư thừa, việc này đồng nghĩa đã vứt bỏ nhiều tín hiệu quan trọng giúp Logistic Regression vẽ đường ranh giới quyết định chính xác.

2. Tại sao mô hình không bị overfit nghiêm trọng

- Nhìn vào bảng số liệu, chênh lệch giữa Train và Test của dữ liệu gốc cực nhỏ. Cho thấy mô hình có khả năng tổng quát hóa rất tốt.
- Cả Train Accuracy và Test Accuracy đều tụt giảm đồng thời. Điều này cho thấy mô hình sau khi giảm chiều đã trở nên "quá đơn giản", không còn đủ độ phức tạp để học được các quy luật trong dữ liệu nữa.

3. Tại sao sau PCA lại tăng khả năng overfit

Trong dữ liệu gốc tồn tại những đặc trưng là nhiễu nhưng lại có sự biến động rất lớn. PCA "nhầm tưởng" đây là thông tin quan trọng và giữ lại, trong khi loại bỏ các đặc trưng có biến động nhỏ nhưng lại chứa thông tin giúp phân loại. Mô hình Logistic Regression buộc phải học theo cái

”Nhiều” có phương sai lớn đó trong tập Train. Vì nhiều ở tập Test không giống hết tập Train, nên kết quả Test bị tụt giảm mạnh hơn Train -> Overfit tăng.

4. Kết luận

Mô hình Logistic Regression cho thấy khả năng phân loại ổn định và đạt hiệu suất cao nhất khi sử dụng dữ liệu gốc. Điều này được thể hiện qua độ chính xác (Accuracy) khá cao và mức chênh lệch rất nhỏ giữa tập huấn luyện và tập kiểm tra, chứng tỏ mô hình có khả năng tổng quát hóa tốt và không bị overfitting.

Mặc dù PCA giúp giảm số chiều dữ liệu, tuy nhiên phương pháp này lại làm giảm đáng kể hiệu suất dự báo trong trường hợp này. Nguyên nhân là do PCA hoạt động dựa trên nguyên tắc giữ lại các chiều có phương sai lớn nhất mà vô tình loại bỏ các đặc trưng có phương sai nhỏ nhưng mang tính quyết định đến nhãn phân loại. Đồng thời, việc cắt giảm xuống còn 1/3 số chiều đã làm mất mát một lượng lớn thông tin cần thiết để mô hình thiết lập đường ranh giới quyết định (decision boundary) chính xác.

7.2.2 Mô hình Naive Bayes

7.2.2.1 Giới thiệu

Naive Bayes là một họ các thuật toán phân loại trong học máy, dựa trên định lý Bayes, với giả định đơn giản hóa rằng các đặc trưng độc lập có điều kiện với nhau khi đã biết nhãn lớp. Mặc dù giả định này thường không hoàn toàn đúng trong thực tế, Naive Bayes vẫn đạt hiệu quả tốt trong nhiều bài toán nhờ tính đơn giản, tốc độ xử lý nhanh và khả năng tổng quát hóa cao.

Thuật toán hoạt động bằng cách ước lượng xác suất hậu nghiệm của từng lớp dựa trên dữ liệu quan sát và gán mẫu dữ liệu vào lớp có xác suất lớn nhất. Naive Bayes đặc biệt phù hợp với các bài toán như phân loại văn bản, lọc thư rác, phân tích cảm xúc, cũng như các tập dữ liệu có số chiều lớn.

Trong dự án này, Gaussian Naive Bayes được sử dụng để phân loại các quốc gia thành ba nhóm dựa trên tuổi thọ, bao gồm tuổi thọ thấp, tuổi thọ trung bình và tuổi thọ cao. Mô hình Gaussian Naive Bayes giả định rằng các đặc trưng đầu vào tuân theo phân phối chuẩn, phù hợp với các dữ liệu số liên tục như trong bài toán đang xét.

7.2.2.2 Cơ sở lý thuyết

(a) Tổng quan thuật toán

Gaussian Naive Bayes (GNB) là một thuật toán phân loại thuộc họ *Naive Bayes*, dựa trên **định lý Bayes** với giả định rằng các đặc trưng đầu vào **độc lập có điều kiện với nhau khi đã biết nhãn lớp**. Thuật toán đặc biệt phù hợp với các bài toán mà đặc trưng là **dữ liệu số liên tục** và có thể được mô hình hóa bằng **phân phối chuẩn (Gaussian distribution)**.

Không giống các mô hình phân biệt (*discriminative models*) như Logistic Regression, Gaussian Naive Bayes là một mô hình **sinh xác suất (generative model)**, nghĩa là nó học phân phối xác suất của dữ liệu trong từng lớp.

(b) Ý tưởng tổng quát

Giả sử ta có tập dữ liệu huấn luyện:

$$\mathcal{D} = \{(x^{(i)}, y^{(i)}) \mid i = 1, 2, \dots, N\}, \quad x^{(i)} \in \mathbb{R}^d, \quad y^{(i)} \in \{1, 2, \dots, C\}.$$

Mục tiêu của Gaussian Naive Bayes là dự đoán nhãn $\hat{y}$ cho một điểm dữ liệu mới x bằng cách cực đại hóa xác suất hậu nghiệm:

$$\hat{y} = \arg \max_c P(y = c \mid x).$$

Theo định lý Bayes:

$$P(y = c \mid x) = \frac{P(x \mid y = c)P(y = c)}{P(x)}.$$

Vì $P(x)$ là hằng số với mọi lớp:

$$\hat{y} = \arg \max_c P(x \mid y = c)P(y = c).$$

(c) Giả định độc lập có điều kiện

Naive Bayes giả định rằng các đặc trưng $x_1, x_2, \dots, x_d$ là **độc lập có điều kiện** khi đã biết lớp $y = c$:

$$P(x \mid y = c) = \prod_{j=1}^d P(x_j \mid y = c).$$

(d) Mô hình Gaussian cho đặc trưng liên tục

Trong Gaussian Naive Bayes, mỗi đặc trưng x_j trong mỗi lớp c được giả định tuân theo phân phối chuẩn:

$$P(x_j \mid y = c) = \frac{1}{\sqrt{2\pi\sigma_{c,j}^2}} \exp\left(-\frac{(x_j - \mu_{c,j})^2}{2\sigma_{c,j}^2}\right),$$

trong đó các tham số $\mu_{c,j}$ và $\sigma_{c,j}^2$ được ước lượng từ dữ liệu huấn luyện của lớp c theo phương pháp **Maximum Likelihood Estimation (MLE)**:

$$(\mu_{c_i}, \sigma_{c_i}^2) = \arg \max_{\mu_{c_i}, \sigma_{c_i}^2} \prod_{n=1}^N p(x_i^{(n)} \mid \mu_{c_i}, \sigma_{c_i}^2)$$

với N là số mẫu thuộc lớp c trong tập dữ liệu huấn luyện.

(e) Ước lượng xác suất tiên nghiệm

$$P(y = c) = \frac{N_c}{N},$$

trong đó N_c là số mẫu thuộc lớp c trong tập huấn luyện.

(f) Hàm quyết định phân lớp

$$\hat{y} = \arg \max_c \left[\log P(y = c) + \sum_{j=1}^d \log P(x_j \mid y = c) \right].$$

(g) **Đánh giá và đặc điểm mô hình**

- **Accuracy:** Accuracy đo lường tỉ lệ dự đoán đúng trên tổng số mẫu:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

- **F1-score:** F1-score là trung bình điều hòa giữa Precision và Recall, được xác định bởi:

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}$$

$$\text{F1-score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

- **Confusion Matrix:** Confusion Matrix biểu diễn số lượng dự đoán đúng và sai của mô hình :

Ma trận nhầm lẫn được biểu diễn như sau:

	Dự đoán dương	Dự đoán âm
Thực tế dương	TP	FN
Thực tế âm	FP	TN

- **Chú thích**

- TP (True Positive): số mẫu thuộc lớp dương được dự đoán đúng là dương.
- TN (True Negative): số mẫu thuộc lớp âm được dự đoán đúng là âm.
- FP (False Positive): số mẫu thuộc lớp âm nhưng bị dự đoán nhầm là dương.
- FN (False Negative): số mẫu thuộc lớp dương nhưng bị dự đoán nhầm là âm.

7.2.2.3 Kết quả và đánh giá

Để đánh giá hiệu suất của mô hình Gaussian Naive Bayes trong bài toán phân loại *tuổi thọ trung bình*, ta tiến hành thử nghiệm với ba tỉ lệ chia tập dữ liệu huấn luyện và kiểm định: **80:20**, **70:30** và **60:40**. Hai dạng dữ liệu được sử dụng gồm:

- **Dữ liệu gốc:** Toàn bộ các đặc trưng sau khi phân cụm và chuẩn hóa.
- **Dữ liệu PCA:** Dữ liệu sau khi giảm chiều bằng phương pháp *Principal Component Analysis*.


(a) **Kết quả thực nghiệm**

Tỉ lệ chia	Loại dữ liệu	Mô hình	Accuracy (Train)	Accuracy (Test)	Chênh lệch (Train-Test)
6:4 (60/40)	Dữ liệu gốc	Naive Bayes	0.7344	0.7151	0.0193
4:1 (80/20)	Dữ liệu gốc	Naive Bayes	0.6983	0.6973	0.0010
7:3 (70/30)	Dữ liệu gốc	Naive Bayes	0.7033	0.6871	0.0162
7:3 (70/30)	Sau PCA (1/3 chiều)	Naive Bayes	0.6741	0.6633	0.0109
4:1 (80/20)	Sau PCA (1/3 chiều)	Naive Bayes	0.6715	0.6565	0.0150
6:4 (60/40)	Sau PCA (1/3 chiều)	Naive Bayes	0.6708	0.6565	0.0144

Bảng 7.3: Kết quả đánh giá mô hình Naive Bayes với các tỉ lệ chia dữ liệu


(b) Phân tích kết quả

1. So sánh giữa các loại dữ liệu




Hình 7.6: So sánh Accuracy (Test) của Naive Bayes giữa dữ liệu gốc và dữ liệu sau PCA

Dựa trên bảng kết quả thực nghiệm và biểu đồ hình 7.6, mô hình Naive Bayes cho hiệu suất tốt hơn khi sử dụng **dữ liệu gốc** so với dữ liệu đã được giảm chiều bằng PCA. Cụ thể, độ chính xác trên tập kiểm tra (Accuracy Test) của dữ liệu gốc dao động trong khoảng từ **0.6871 đến 0.7151**, trong khi dữ liệu sau PCA chỉ đạt từ **0.6565 đến 0.6633**.



Hình 7.7: Confusion matrix của mô hình Naive Bayes tại tỉ lệ chia 7:3 (dữ liệu gốc)

Một điểm đáng chú ý là tại tỉ lệ 7:3 của dữ liệu gốc, giá trị trên đường chéo chính chiếm tỷ trọng lớn, cho thấy mô hình dự đoán đúng phần lớn các mẫu thuộc từng lớp, phản ánh khả năng phân loại tương đối tốt. Tuy nhiên, vẫn tồn tại một số nhầm lẫn giữa các lớp, đặc biệt là các mẫu thuộc lớp tuổi thọ cao (lớp số 2) bị dự đoán sai sang các lớp lân cận nhiều nhất.



Hình 7.8: Confusion matrix của mô hình Naive Bayes tại tỉ lệ chia 7:3 (dữ liệu giảm chiều pca)

Ma trận nhầm lẫn tại tỉ lệ 7:3 của dữ liệu sau giảm chiều chiếm tỷ trọng lớn nhưng kém hơn so với dữ liệu gốc, mô hình dự đoán có vẻ thiên về lớp tuổi thọ trung bình (lớp 1) nhiều hơn


Điều này cho thấy quá trình giảm chiều bằng PCA (giữ lại 1/3 số chiều ban đầu) có thể đã làm mất đi một phần thông tin quan trọng phục vụ cho việc phân loại. Trong khi đó, Naive Bayes vốn có khả năng xử lý tốt dữ liệu nhiều đặc trưng, nên việc sử dụng dữ liệu gốc mang lại kết quả tốt hơn.

2. Ảnh hưởng của tỉ lệ chia dữ liệu

Xét trong cùng một loại dữ liệu, quan sát hình 7.6, sự thay đổi tỉ lệ chia tập huấn luyện và tập kiểm tra chỉ gây ra sự dao động nhẹ về độ chính xác. Trên dữ liệu gốc, tỉ lệ **6:4 (60/40)** cho kết quả Accuracy (Test) cao nhất là **0.7151**, trong khi các tỉ lệ **7:3 (70/30)** và **4:1 (80/20)** cho kết quả thấp hơn không đáng kể.

Điều này cho thấy mô hình Naive Bayes **không quá nhạy cảm với tỉ lệ chia dữ liệu**, và hiệu năng tương đối ổn định khi phân bố mẫu giữa tập huấn luyện và tập kiểm tra không chênh lệch quá lớn.

3. Độ chênh lệch Accuracy (Train–Test) và hiện tượng overfitting



Hình 7.9: Chênh lệch Accuracy giữa tập Train và Test của mô hình Naive Bayes

Quan sát cột **Chênh lệch (Train–Test)** và hình 7.9 cho thấy sự khác biệt giữa độ chính xác trên tập huấn luyện và tập kiểm tra đều rất nhỏ, dao động trong khoảng từ **0.001 đến 0.019**.

Điều này cho thấy mô hình Naive Bayes **không có dấu hiệu overfitting rõ rệt**, vì hiệu năng trên tập huấn luyện và tập kiểm tra gần như tương đương. Đặc biệt, với tỉ lệ chia **4:1 (80/20)** trên dữ liệu gốc, độ chênh lệch chỉ là **0.001**, phản ánh khả năng tổng quát hóa tốt của mô hình.

(c) Nhận xét tổng quan

Từ các nhận xét, bảng và các biểu đồ, có thể thấy mô hình Naive Bayes cho hiệu năng khá ổn định trong bài toán phân loại:

- Mô hình Naive Bayes đạt độ chính xác tốt hơn khi sử dụng **dữ liệu gốc** so với dữ liệu sau khi giảm chiều bằng PCA, với Accuracy (Test) cao nhất đạt **0.7151** tại tỉ lệ chia 6:4.
- Việc thay đổi tỉ lệ chia dữ liệu huấn luyện và kiểm tra chỉ gây ra sự dao động nhẹ về độ chính xác, cho thấy mô hình **không quá nhạy cảm với tỉ lệ chia dữ liệu** và duy trì tính ổn định tương đối tốt.
- Chênh lệch giữa Accuracy trên tập train và tập test ở tất cả các trường hợp đều nhỏ (dưới 0.02), cho thấy mô hình **không có dấu hiệu overfitting rõ rệt** và có khả năng tổng quát hóa tốt.
- Phương pháp giảm chiều PCA (giữ lại 1/3 số chiều ban đầu) không mang lại cải thiện về hiệu năng, thậm chí làm giảm nhẹ độ chính xác, cho thấy PCA chưa thực sự phù hợp với mô hình Naive Bayes trong bài toán này.

(d) Tại sao ta nhận được kết quả thực nghiệm như vậy

Các kết quả thực nghiệm thu được phản ánh khá rõ đặc điểm và giá định nền tảng của mô hình Naive Bayes khi áp dụng vào bài toán phân loại tuổi thọ. Trước hết, mô hình Naive Bayes cho thấy khả năng phân loại ổn định và ít bị overfitting, thể hiện qua sự chênh lệch nhỏ giữa độ chính xác trên tập huấn luyện và tập kiểm tra ở hầu hết các tỉ lệ chia dữ liệu. Điều này xuất phát từ bản chất của Naive Bayes là một mô hình có độ phức tạp thấp, số lượng tham số cần ước lượng ít và không học ranh giới phân lớp một cách trực tiếp, do đó hạn chế được hiện tượng ghi nhớ dữ liệu huấn luyện.

Bên cạnh đó, Naive Bayes đạt hiệu năng tốt hơn khi sử dụng dữ liệu gốc so với dữ liệu đã qua giảm

chiều bằng PCA. Mặc dù PCA giúp giảm số chiều và loại bỏ nhiễu, phương pháp này chỉ tối ưu theo phương sai của dữ liệu mà không xét đến thông tin phân biệt giữa các lớp. Do đó, khi chỉ giữ lại 1/3 số chiều ban đầu, một số đặc trưng có phương sai thấp nhưng mang ý nghĩa quan trọng đối với việc phân loại có thể bị loại bỏ, làm suy giảm hiệu năng của mô hình.

Ngoài ra, mối quan hệ giữa các đặc trưng trong dữ liệu thực tế tồn tại sự tương quan nhất định, trong khi Naive Bayes lại dựa trên giả định các đặc trưng độc lập có điều kiện theo lớp. Giả định này không hoàn toàn phù hợp với dữ liệu của bài toán, dẫn đến việc mô hình không thể học được ranh giới phân lớp tối ưu. Vì vậy, khi tăng tỉ lệ dữ liệu huấn luyện, mô hình không thu nhận thêm được thông tin hữu ích để cải thiện khả năng phân biệt giữa các lớp, khiến độ chính xác không tăng đáng kể mà có xu hướng bão hòa.

(e) **Kết luận**

Nhìn chung, các kết quả thực nghiệm thu được là phù hợp với đặc điểm lý thuyết của mô hình Naive Bayes. Mô hình cho thấy tính ổn định cao và ít bị overfitting, tuy nhiên do giả định độc lập giữa các đặc trưng không hoàn toàn phù hợp với dữ liệu thực tế và việc áp dụng PCA làm mất một phần thông tin phân biệt theo lớp, hiệu năng của mô hình không được cải thiện khi tăng tỉ lệ dữ liệu huấn luyện cũng như khi giảm chiều dữ liệu.

7.3 So sánh hai mô hình Naive Bayes và Logistic Regression

7.3.1 Mô tả dữ liệu và thiết lập so sánh

**Bảng tổng hợp kết quả đánh giá mô hình
(Accuracy & F1-score)**


Tỉ lệ chia	Loại dữ liệu	Mô hình	Accuracy (Test)	F1-score (Macro)
4:1 (80/20)	Dữ liệu gốc	Logistic Regression	0.7874	0.788
7:3 (70/30)	Dữ liệu gốc	Logistic Regression	0.8005	0.801
6:4 (60/40)	Dữ liệu gốc	Logistic Regression	0.7917	0.7925
4:1 (80/20)	Sau PCA (1/3 chiều)	Logistic Regression	0.7415	0.7436
7:3 (70/30)	Sau PCA (1/3 chiều)	Logistic Regression	0.754	0.7561
6:4 (60/40)	Sau PCA (1/3 chiều)	Logistic Regression	0.7611	0.7634
4:1 (80/20)	Dữ liệu gốc	Naive Bayes	0.6973	0.6566
7:3 (70/30)	Dữ liệu gốc	Naive Bayes	0.6871	0.6399
6:4 (60/40)	Dữ liệu gốc	Naive Bayes	0.7151	0.688
4:1 (80/20)	Sau PCA (1/3 chiều)	Naive Bayes	0.6565	0.6638
7:3 (70/30)	Sau PCA (1/3 chiều)	Naive Bayes	0.6633	0.6711
6:4 (60/40)	Sau PCA (1/3 chiều)	Naive Bayes	0.6565	0.664

Hình 7.10: Tổng quan dữ liệu

Hai mô hình Naive Bayes và Logistic Regression được so sánh dựa trên cùng một tập dữ liệu và cùng quy trình tiền xử lý nhằm đảm bảo tính công bằng trong đánh giá. Các thí nghiệm được thực hiện trên hai loại dữ liệu: **dữ liệu gốc** và **dữ liệu sau khi giảm chiều bằng PCA**. Hai chỉ số đánh giá chính được sử dụng là **Accuracy** và **F1-score**, phản ánh lần lượt độ chính xác tổng thể và khả năng cân bằng giữa Precision và Recall của mô hình.

7.3.2 So sánh theo chỉ số Accuracy


7.3.2.1 Trên dữ liệu gốc



Hình 7.11: So sánh Accuracy của Naive Bayes và Logistic Regression trên dữ liệu gốc

Từ biểu đồ 7.11 có thể nhận thấy rằng hai mô hình đều đạt độ chính xác tương đối ổn định trên dữ liệu gốc. Trong tất cả các tỉ lệ chia dữ liệu, Logistic Regression cho kết quả Accuracy cao hơn, cho thấy khả năng khai thác mối quan hệ giữa các đặc trưng tốt hơn.

7.3.2.2 Trên dữ liệu sau PCA




Hình 7.12: So sánh Accuracy của Naive Bayes và Logistic Regression trên dữ liệu sau PCA

Khi áp dụng PCA để giảm chiều dữ liệu biểu đồ 7.12, Accuracy của cả hai mô hình đều giảm. Mô hình Logistic Regression chịu ảnh hưởng rõ rệt hơn, cho thấy việc giảm chiều đã làm mất đi một phần thông tin

quan trọng đối với quá trình phân loại.

7.3.3 So sánh theo chỉ số F1-score


7.3.3.1 Trên dữ liệu gốc



Hình 7.13: So sánh F1-score của Naive Bayes và Logistic Regression trên dữ liệu gốc

Xét theo chỉ số F1-score, mô hình có giá trị cao hơn thể hiện khả năng cân bằng tốt hơn giữa Precision và Recall. Kết quả tại biểu đồ 7.13 cho thấy Logistic Regression có xu hướng duy trì F1-score cao và ổn định hơn, đặc biệt trong bối cảnh dữ liệu có sự chồng lấn giữa các lớp theo các confusion matrix ở mục các model.

7.3.3.2 Trên dữ liệu sau PCA



Hình 7.14: So sánh F1-score của Naive Bayes và Logistic Regression trên dữ liệu sau PCA

Sau khi giảm chiều bằng PCA, biểu đồ 7.14 cho thấy F1-score của cả hai mô hình đều giảm nhẹ. Điều này cho thấy PCA chưa thực sự cải thiện khả năng phân loại trong bài toán này, đặc biệt là đối với việc nhận diện chính xác các lớp khó phân biệt.

7.3.4 Đánh giá tổng hợp

Tổng hợp các kết quả trên, có thể rút ra một số nhận xét chính:

- Logistic Regression cho hiệu năng tổng thể tốt hơn khi xét đồng thời cả Accuracy và F1-score.
- Naive Bayes thể hiện tính ổn định cao và ít bị ảnh hưởng bởi thay đổi tỉ lệ chia dữ liệu.
- Việc tăng tỉ lệ dữ liệu train không làm thay đổi quá nhiều chỉ số chính xác của cả 2 mô hình. Chứng tỏ rằng không phải mô hình học càng nhiều dữ liệu càng tốt.
- PCA không mang lại cải thiện rõ rệt cho cả hai mô hình, thậm chí làm giảm nhẹ hiệu suất trong một số trường hợp. Chứng tỏ việc giảm chiều làm mất đi một số thông tin quan trọng cho việc phân loại.

Như vậy, có thể nhận thấy rằng Logistic Regression là mô hình phù hợp hơn cho bài toán này. Nguyên nhân là do các yếu tố ảnh hưởng đến tuổi thọ trung bình của các quốc gia không tồn tại một cách độc lập, mà có mối tương quan chặt chẽ với nhau (chẳng hạn như giữa phân bố thu nhập GDP và chất lượng giáo dục (Số năm học trung bình)). Logistic Regression không đưa ra giả định về tính độc lập giữa các đặc trưng, do đó có khả năng học được ranh giới phân lớp hiệu quả hơn. Ngược lại, Gaussian Naive Bayes giả định các đặc trưng là độc lập có điều kiện theo lớp, khiến mô hình khó khai thác đầy đủ mối quan hệ giữa các biến trong bối cảnh dữ liệu thực tế này.

Chương 8

Kết luận

Dự án đã hoàn thành toàn diện quy trình phân tích và dự đoán tuổi thọ trung bình dựa trên các yếu tố y tế - xã hội, từ tiền xử lý dữ liệu, giảm chiều, đến đánh giá hiệu suất các mô hình hồi quy. Các kết quả chính được tóm tắt như sau:

1. Tiền xử lý dữ liệu

- Xử lý thành công **2563 giá trị thiếu (3.97%)** bằng phương pháp `SimpleImputer(strategy='mean')`, đảm bảo không còn giá trị NaN.
- Loại bỏ cột `Country` (193 giá trị duy nhất) để tránh *curse of dimensionality*; thay vào đó, thông tin địa lý được biểu diễn gián tiếp qua `GDP`, `Schooling`, `Status`.
- Mã hóa One-Hot cho biến `Status` (Developed/Developing) với `drop_first=True` để tránh đa cộng tuyến.
- Chuẩn hóa dữ liệu bằng `StandardScaler`: $\text{mean} \approx 0$, $\text{std} \approx 1$, đảm bảo tính ổn định cho các mô hình nhạy cảm với thang đo.

2. Giảm chiều dữ liệu

- **PCA**: Giảm từ 20 chiều xuống **15 thành phần chính** (giảm 25%), giữ lại **95% phương sai** trên tập huấn luyện và **96.55%** trên tập kiểm tra. Thành phần chính đầu tiên (PC1) giải thích $\sim 42\%$ phương sai, đại diện cho trục *phát triển kinh tế - xã hội*.
- **SelectKBest (f_regression)**: Chọn **10 đặc trưng quan trọng nhất**, bao gồm: `Schooling`, `Income composition`, `Adult Mortality`, `HIV/AIDS`, `BMI`, `Polio`, `Diphtheria`, `thinness`, `Status_Developing`.
- So sánh: PCA giảm chiều không giám sát, giữ variance tốt; SelectKBest giám sát, giữ nguyên ý nghĩa đặc trưng, dễ diễn giải.

3. Đánh giá mô hình hồi quy

Hai mô hình **KNN Regressor** và **Linear Regression** được thử nghiệm trên 3 loại dữ liệu (*gốc*, *PCA*, *SelectKBest*) với 3 tỉ lệ chia: 80:20, 70:30, 60:40.

3.1. K-Nearest Neighbors (KNN)

- Sử dụng $k = \lfloor \sqrt{n} \rfloor$, khoảng cách Manhattan, $\text{weights}=\text{uniform}$.
- **Kết quả nổi bật:**
 - Dữ liệu *SelectKBest* đạt **Test R^2 cao nhất: 0.886** (60:40), **MSE = 3.23**.
 - Dữ liệu *gốc*: $\text{Test } R^2 \in [0.872, 0.877]$, $\text{MSE} \approx 3.5$.
 - *PCA*: $\text{Test } R^2$ thấp nhất (≈ 0.83), MSE cao nhất (≈ 4.0).
- **Overfit**: Không xảy ra ($\Delta R^2 < 0.05$ trong mọi trường hợp).
- *SelectKBest* giảm ΔR^2 trung bình **33.3%** so với dữ liệu gốc $\rightarrow$ **mô hình ổn định và chính xác nhất**.

3.2. Linear Regression

- Dữ liệu gốc cho **Test R^2 cao nhất: 0.806** (70:30), $\text{MSE} \approx 16.85$.
- *PCA*: $\text{Test } R^2 \approx 0.79$, giảm ΔR^2 trung bình **13.0%** so với gốc $\rightarrow$ cải thiện tổng quát hóa.
- *SelectKBest*: $\text{Test } R^2 \approx 0.78\text{--}0.79$, hiệu suất thấp hơn gốc nhưng vẫn ổn định.
- **Tỉ lệ 70:30 là tối ưu** cho cả hai mô hình: cân bằng giữa độ chính xác và độ ổn định.

4. Ý nghĩa thực tiễn

- Xác định các yếu tố then chốt ảnh hưởng đến tuổi thọ: *Schooling*, *Income composition*, *Adult Mortality*, *HIV/AIDS*.
- Hỗ trợ **nhà hoạch định chính sách** ưu tiên đầu tư vào giáo dục, y tế cơ bản, kiểm soát dịch bệnh.
- **Dự báo xu hướng tuổi thọ** theo kịch bản phát triển kinh tế - xã hội.

5. Hạn chế và hướng phát triển

- **Hạn chế:**
 - Dữ liệu chỉ đến năm 2015 $\rightarrow$ cần cập nhật dữ liệu gần đây.
 - *Mean Imputation* có thể làm giảm phương sai, gây bias nhẹ.
 - Chưa khai thác đầy đủ *mối quan hệ phi tuyến* giữa các biến.
 - KNN tốn tài nguyên tính toán khi dữ liệu lớn.
- **Hướng phát triển:**

- Thử nghiệm mô hình phi tuyến: Random Forest, XGBoost, SVR.
- Áp dụng Ridge/Lasso để kiểm soát đa cộng tuyến và cải thiện Linear Regression.
- Sử dụng Cross-validation (5-fold, 10-fold) thay vì chia đơn.
- Phân tích độ quan trọng đặc trưng bằng SHAP hoặc Permutation Importance.
- Xây dựng **dashboard tương tác** (Streamlit/Dash) để trực quan hóa dự đoán theo quốc gia/năm.
- Mở rộng dữ liệu: thêm biến khí hậu, đô thị hóa, ô nhiễm.

6 Phân cụm dữ liệu

- Số cụm tối ưu được xác định là $K = 3$ dựa trên tổng hợp các chỉ số đánh giá
- GMM cho kết quả phân bố cân bằng hơn K-Means (877, 1300, 761 mẫu so với 1226, 1692, 20 mẫu)
- Kiểm định ANOVA cho thấy sự khác biệt có ý nghĩa thống kê về Life Expectancy giữa các cụm ($p\text{-value} < 0.0001$)

7. Chuyển qua bài toán phân loại

7.1 Tạo nhãn phân loại

Tạo 3 loại nhãn với phân bố:

- Nhãn 0 (Thấp): Life expectancy < 66.6
- Nhãn 1 (Trung bình): $66.6 \leq \text{Life expectancy} < 74.4$
- Nhãn 2 (Cao): Life expectancy ≥ 74.4

7.2 Các mô hình phân loại

7.2.1 Logistic regression

- Hiệu quả trên dữ liệu gốc: Logistic Regression đạt độ chính xác cao nhất và hoạt động ổn định. Chênh lệch Train-Test rất nhỏ cho thấy mô hình tổng quát hóa tốt và không bị Overfitting
- PCA làm giảm hiệu suất: Việc áp dụng PCA khiến độ chính xác sụt giảm do thuật toán ưu tiên giữ lại các chiều có phương sai lớn (Variance) mà vô tình loại bỏ các đặc trưng quan trọng đối với việc phân loại.

7.2.2 Naive Bayes

- Mô hình Naive Bayes cho kết quả tốt hơn khi sử dụng **dữ liệu gốc**, với Accuracy (Test) cao nhất đạt **0.7151** tại tỉ lệ chia 6:4.
- Độ chính xác của mô hình chỉ dao động nhẹ khi thay đổi tỉ lệ chia dữ liệu, cho thấy mô hình **ổn định và không nhạy cảm** với cách chia tập.
- Chênh lệch Accuracy giữa tập train và test đều nhỏ (dưới 0.02), cho thấy mô hình **không bị overfitting** và có khả năng tổng quát hóa tốt.

- Việc áp dụng PCA (giữ lại 1/3 số chiều) không cải thiện mà còn làm giảm nhẹ hiệu năng, cho thấy PCA **chưa phù hợp** với Naive Bayes trong bài toán này.

7.3 So sánh 2 mô hình

- Logistic Regression cho hiệu năng tổng thể tốt hơn khi xét đồng thời cả Accuracy và F1-score.
- Naive Bayes thể hiện tính ổn định cao, ít bị ảnh hưởng bởi sự thay đổi tỉ lệ chia dữ liệu.
- Việc tăng tỉ lệ dữ liệu huấn luyện không làm cải thiện đáng kể độ chính xác của cả hai mô hình, cho thấy hiệu năng không chỉ phụ thuộc vào số lượng dữ liệu train.
- Phương pháp PCA không mang lại cải thiện rõ rệt cho cả hai mô hình, thậm chí làm giảm nhẹ hiệu suất trong một số trường hợp, cho thấy việc giảm chiều có thể làm mất thông tin quan trọng phục vụ cho phân loại.

Tóm lại

Dự án đã xây dựng thành công một **hệ thống phân tích và dự đoán tuổi thọ toàn diện**, bao gồm cả bài toán **hồi quy** và **phân loại**. Cụ thể:

- Thực hiện quy trình tiền xử lý dữ liệu đầy đủ và nhất quán, bao gồm làm sạch, chuẩn hóa và xử lý đặc trưng.
- Áp dụng hai phương pháp giảm chiều dữ liệu: **PCA** (bảo toàn phương sai) và **SelectKBest** (giữ lại các đặc trưng có ý nghĩa), phục vụ cho các bài toán học máy khác nhau.
- Trong bài toán hồi quy, tổ hợp **SelectKBest + KNN** cho kết quả tốt nhất với $R^2 = 0.886$, $MSE = 3.23$, đồng thời không xuất hiện hiện tượng overfitting; tỉ lệ chia **train:test = 70:30** cho thấy hiệu năng ổn định đối với cả KNN và Linear Regression.
- Ngoài ra, dữ liệu được **phân cụm và gán nhãn** để chuyển đổi thành bài toán phân loại. Kết quả cho thấy **Logistic Regression** là mô hình phân loại phù hợp hơn so với Naive Bayes khi xét đồng thời các chỉ số Accuracy và F1-score.

Kết quả tạo nền tảng vững chắc cho giai đoạn tiếp theo: **xây dựng mô hình dự đoán chính xác cao, triển khai thực tế**.

Tài liệu tham khảo

- [1] World Health Organization, *Life Expectancy Data*, <https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who>
- [2] Vũ Hữu Tiệp, *Machine Learning cơ bản*, <https://github.com/tiepvupsu/ebookMLCB>
- [3] Nguyễn Thanh Tuấn, *Deep Learning cơ bản*, <https://drive.google.com/file/d/1lNjzISABdoc7SRq8tg-xkCRRZRABPCKi/view>
- [4] Scikit-learn Documentation, *Principal Component Analysis (PCA)*, <https://scikit-learn.org/stable/modules/decomposition.html#pca>
- [5] L. van der Maaten and G. Hinton, “Visualizing Data using t-SNE”, *Journal of Machine Learning Research*, vol. 9, pp. 2579-2605, 2008.
- [6] Pandas Development Team, *pandas: powerful Python data analysis toolkit*, <https://pandas.pydata.org/>