

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN - CƠ - TIN HỌC



MACHINE LEARNING

Chủ đề

DỰ ĐOÁN TUỔI THỌ TRUNG BÌNH
DỰA TRÊN CÁC YẾU TỐ Y TẾ - XÃ HỘI

Giảng viên hướng dẫn: TS. Cao Văn Chung

Nhóm sinh viên thực hiện:

<i>Họ và tên</i>	<i>MSSV</i>	<i>Lớp</i>
Đình Quang Tiến	23001943	K68A4
Nguyễn Đức Quang	23001918	K68A4
Hà Minh Quang	23001916	K68A4

Hà Nội, 2025

Tóm Tắt Nội Dung

Dự án này tập trung vào việc ứng dụng các mô hình học máy để dự đoán tuổi thọ trung bình (Life Expectancy) dựa trên bộ dữ liệu Life Expectancy Data của Tổ chức Y tế Thế giới (WHO). Đây là một bài toán hồi quy điển hình, trong đó mục tiêu là dự đoán một giá trị liên tục dựa trên nhiều yếu tố y tế và xã hội như tỷ lệ tử vong người lớn, tỷ lệ tiêm chủng, GDP, chỉ số BMI, và nhiều yếu tố khác.

Phần đầu tiên của báo cáo trình bày cơ sở lý thuyết về các kỹ thuật tiền xử lý dữ liệu, bao gồm xử lý giá trị thiếu, chuẩn hóa dữ liệu, và mã hóa biến phân loại. Phần thứ hai tập trung vào các phương pháp giảm chiều, cụ thể là Phân tích thành phần chính (PCA) và lựa chọn đặc trưng với SelectKBest, nhằm giảm số chiều dữ liệu từ 20 features xuống không gian có chiều thấp hơn trong khi vẫn giữ lại phần lớn thông tin quan trọng.

Dữ liệu được chia thành tập huấn luyện (70%) và tập kiểm tra (30%) với 2938 quan sát từ 193 quốc gia trong giai đoạn 2000-2015. Sau khi tiền xử lý, PCA được áp dụng để giảm chiều từ 20 features xuống 15 thành phần chính, giữ lại 95% phương sai của dữ liệu gốc. SelectKBest được sử dụng để chọn ra 10 features quan trọng nhất dựa trên F-statistic. Kết quả cho thấy phương sai giải thích của PCA đạt 96.55% trên tập kiểm tra.

Báo cáo này nhấn mạnh tầm quan trọng của việc phân tích và xử lý dữ liệu y tế để xây dựng các mô hình dự đoán đáng tin cậy, góp phần hỗ trợ các nhà hoạch định chính sách trong việc đưa ra quyết định về đầu tư y tế và phát triển xã hội.

Mục lục

1	Lý do chọn đề tài	4
2	Tiền xử lý dữ liệu	5
2.1	Tổng quan về bộ dữ liệu	5
2.2	Xử lý giá trị thiếu	6
2.3	Mã hóa biến phân loại	7
2.4	Chuẩn hóa dữ liệu	8
3	Giảm chiều và trực quan hóa dữ liệu	10
3.1	Phân tích thành phần chính (PCA)	10
3.1.1	Mục đích	10
3.1.2	Cơ sở lý thuyết	10
3.1.3	Các bước thực hiện	11
3.1.4	Kết quả thực nghiệm	12
3.2	Lựa chọn đặc trưng với SelectKBest	14
3.2.1	Giới thiệu về SelectKBest	14
3.2.2	Phương pháp $f_{\text{regression}}$	14
3.2.3	Kết quả thực nghiệm	15
3.3	So sánh PCA và SelectKBest	15
4	Phương pháp hồi quy sử dụng KNN	17
4.1	Giới thiệu	17
4.2	Cách thuật toán KNN hoạt động trong bài toán hồi quy	17
4.2.1	Ý tưởng tổng quát	18
4.2.2	Tính khoảng cách giữa các điểm	18
4.2.3	Chuẩn hóa dữ liệu (Feature Scaling)	19
4.2.4	Cách tính giá trị dự đoán	19
4.2.5	Quy trình thuật toán (pseudocode)	19
4.2.6	Chọn giá trị k phù hợp	19
4.2.7	Đánh giá hiệu quả mô hình	19
4.2.8	Tóm tắt	20
4.3	Phương pháp KNN với bài toán hồi quy dự đoán tuổi thọ trung bình	20
4.3.1	Đánh giá hiệu suất mô hình theo các tỉ lệ chia dữ liệu	20
4.3.2	Kết quả thực nghiệm	20
4.3.3	Phân tích kết quả	20

4.3.4	Thực quan hóa phần dư	22
4.3.5	Nhận xét tổng quan	23
5	Phương pháp Linear Regression với bài toán hồi quy dự đoán tuổi thọ trung bình	24
5.1	Cách thuật toán Linear Regression hoạt động	24
5.1.1	Mô hình tổng quát	24
5.1.2	Hàm mất mát (Loss function)	24
5.1.3	Quá trình huấn luyện mô hình	25
5.1.4	Dự đoán giá trị tuổi thọ trung bình	25
5.1.5	Ưu và nhược điểm	25
5.2	Đánh giá hiệu suất mô hình theo các tỉ lệ chia dữ liệu	25
5.2.1	Kết quả thực nghiệm	26
5.2.2	Phân tích kết quả	26
5.2.3	Thực quan hóa phần dư	28
5.3	Nhận xét tổng quan	28
6	Kết luận	30

Chương 1

Lý do chọn đề tài

Tuổi thọ trung bình là một chỉ số quan trọng phản ánh mức độ phát triển kinh tế - xã hội và chất lượng hệ thống y tế của một quốc gia. Theo Tổ chức Y tế Thế giới (WHO), tuổi thọ trung bình toàn cầu đã tăng đáng kể trong những thập kỷ qua, nhưng vẫn tồn tại sự chênh lệch lớn giữa các quốc gia và khu vực. Việc hiểu rõ các yếu tố ảnh hưởng đến tuổi thọ có ý nghĩa quan trọng trong việc hoạch định chính sách y tế, phân bổ nguồn lực và cải thiện chất lượng cuộc sống của người dân.

Trong bối cảnh dữ liệu y tế ngày càng phong phú và công nghệ học máy phát triển mạnh mẽ, việc ứng dụng các kỹ thuật phân tích dữ liệu và mô hình hóa dự đoán trở thành công cụ đắc lực để khám phá các mối quan hệ phức tạp giữa các yếu tố y tế - xã hội và tuổi thọ. Các mô hình học máy có khả năng xử lý dữ liệu đa chiều, phát hiện các mẫu tiềm ẩn mà phương pháp thống kê truyền thống khó nhận ra.

Đề tài này sử dụng bộ dữ liệu Life Expectancy Data từ WHO, bao gồm thông tin từ 193 quốc gia trong giai đoạn 2000-2015, với 22 biến số liên quan đến y tế, kinh tế và xã hội. Đây là một bài toán hồi quy điển hình, trong đó mục tiêu là dự đoán tuổi thọ trung bình dựa trên các yếu tố như tỷ lệ tử vong người lớn, tỷ lệ tử vong trẻ sơ sinh, tỷ lệ tiêm chủng, GDP, chỉ tiêu y tế, tình trạng dinh dưỡng, và mức độ giáo dục.

Thông qua việc triển khai các bước tiền xử lý dữ liệu (xử lý giá trị thiếu, mã hóa biến phân loại, chuẩn hóa), áp dụng các kỹ thuật giảm chiều (PCA, SelectKBest), và xây dựng các mô hình học máy, dự án không chỉ giúp người học nâng cao kỹ năng thực hành mà còn đóng góp vào việc hiểu sâu hơn về các nhân tố quyết định tuổi thọ con người.

Chương 2

Tiền xử lý dữ liệu

2.1 Tổng quan về bộ dữ liệu

Bộ dữ liệu Life Expectancy Data được thu thập từ Tổ chức Y tế Thế giới (WHO) và các nguồn dữ liệu thống kê của Liên Hợp Quốc, bao gồm thông tin từ 193 quốc gia trong giai đoạn từ năm 2000 đến 2015. Dữ liệu gồm **2938 quan sát** và **22 biến số**, trong đó biến mục tiêu (target) là **Life expectancy** (tuổi thọ trung bình).

Các biến trong bộ dữ liệu:

1. **Country:** Tên quốc gia (193 giá trị unique)
2. **Year:** Năm thu thập dữ liệu (2000-2015)
3. **Status:** Trạng thái phát triển (Developed/Developing)
4. **Life expectancy:** Tuổi thọ trung bình (năm) - *Biến mục tiêu*
5. **Adult Mortality:** Tỷ lệ tử vong người lớn (trên 1000 dân)
6. **infant deaths:** Số trẻ sơ sinh tử vong (trên 1000 dân)
7. **Alcohol:** Tiêu thụ rượu bình quân đầu người (lít)
8. **percentage expenditure:** Chi tiêu y tế chiếm % GDP
9. **Hepatitis B:** Tỷ lệ tiêm chủng viêm gan B (%)
10. **Measles:** Số ca sởi (trên 1000 dân)
11. **BMI:** Chỉ số khối cơ thể trung bình
12. **under-five deaths:** Số trẻ dưới 5 tuổi tử vong (trên 1000 dân)
13. **Polio:** Tỷ lệ tiêm chủng bại liệt (%)
14. **Total expenditure:** Tổng chi tiêu y tế chiếm % GDP
15. **Diphtheria:** Tỷ lệ tiêm chủng bạch hầu (%)
16. **HIV/AIDS:** Số ca tử vong do HIV/AIDS (trên 1000 dân)
17. **GDP:** GDP bình quân đầu người (USD)

18. **Population:** Dân số quốc gia
19. **thinness 1-19 years:** Tỷ lệ suy dinh dưỡng ở trẻ 1-19 tuổi (%)
20. **thinness 5-9 years:** Tỷ lệ suy dinh dưỡng ở trẻ 5-9 tuổi (%)
21. **Income composition of resources:** Chỉ số phân bổ thu nhập (0-1)
22. **Schooling:** Số năm học trung bình

Thống kê mô tả biến mục tiêu:

Biến Life expectancy có các đặc điểm sau:

- Số quan sát: 2928 (có 10 giá trị thiếu)
- Giá trị trung bình: 69.22 năm
- Độ lệch chuẩn: 9.52 năm
- Giá trị nhỏ nhất: 36.3 năm
- Trung vị: 72.1 năm
- Giá trị lớn nhất: 89.0 năm

Phân bố của biến mục tiêu cho thấy dữ liệu có phân phối tương đối cân đối, với giá trị trung bình và trung vị gần nhau (69.22 và 72.1), cho thấy phân phối không bị lệch đáng kể. Tuy nhiên, khoảng cách từ giá trị nhỏ nhất (36.3) đến giá trị lớn nhất (89.0) khá lớn, phản ánh sự chênh lệch về tuổi thọ giữa các quốc gia.

2.2 Xử lý giá trị thiếu

Một trong những thách thức chính khi làm việc với dữ liệu thực tế là vấn đề giá trị thiếu (missing values). Trong bộ dữ liệu này, tổng cộng có **2563 giá trị thiếu** (chiếm 3.97% tổng số dữ liệu), phân bố không đều qua các biến.

Phân tích giá trị thiếu:

Các biến có số lượng giá trị thiếu cao nhất được liệt kê trong bảng:

Biến	Số giá trị thiếu	Tỷ lệ (%)
Population	652	22.19
Hepatitis B	553	18.82
GDP	448	15.25
Total expenditure	226	7.69
Alcohol	194	6.60
Income composition of resources	167	5.68
Schooling	163	5.55
BMI, thinness 1-19, thinness 5-9	34	1.16
Polio, Diphtheria	19	0.65
Life expectancy, Adult Mortality	10	0.34

Bảng 2.1: Phân tích giá trị thiếu theo biến

Phương pháp xử lý:

Để xử lý giá trị thiếu, nhóm áp dụng phương pháp **Mean Imputation** (điền bằng giá trị trung bình) sử dụng SimpleImputer từ thư viện scikit-learn. Đây là một phương pháp phổ biến và phù hợp cho dữ liệu số, dựa trên công thức:

$$x_{missing} = \bar{x} = \frac{1}{N} \sum_{i=1}^N x_i \quad (2.1)$$

Trong đó:

- $x_{missing}$ là giá trị cần điền
- $\bar{x}$ là giá trị trung bình của cột
- N là số quan sát có giá trị (không thiếu)

Quy trình thực hiện:

1. **Xử lý biến mục tiêu trước:** Điền 10 giá trị thiếu trong cột Life expectancy bằng giá trị trung bình 69.22 năm.
2. **Xử lý các biến số:** Áp dụng Mean Imputation cho 18 biến số còn lại (loại trừ Year vì không có giá trị thiếu).
3. **Kiểm tra kết quả:** Sau khi xử lý, số lượng giá trị thiếu giảm từ 2563 xuống 0, đảm bảo dữ liệu hoàn chỉnh cho các bước tiếp theo.

2.3 Mã hóa biến phân loại

Trong bộ dữ liệu có hai biến phân loại (categorical variables): **Country** và **Status**.

Xử lý biến Country:

Biến Country có 193 giá trị unique (tương ứng với 193 quốc gia). Nếu áp dụng One-Hot Encoding, sẽ tạo ra 192 cột dummy mới, dẫn đến:

- **Curse of dimensionality:** Số chiều tăng đột biến
- **Overfitting:** Mô hình dễ học thuộc lòng dữ liệu huấn luyện
- **Multicollinearity:** Các biến dummy có tương quan cao với nhau

Do đó, nhóm quyết định **loại bỏ biến Country** khỏi tập dữ liệu vì thông tin về quốc gia đã được thể hiện gián tiếp qua các biến khác như GDP, Schooling, Status, Population, và các chỉ số y tế.

Xử lý biến Status:

Biến Status chỉ có 2 giá trị: “Developed” (Phát triển) và “Developing” (Đang phát triển). Đây là biến phân loại nhị phân, phù hợp để mã hóa bằng phương pháp **One-Hot Encoding** với tham số `drop_first=True`.

Công thức mã hóa:

$$\text{Status_Developing} = \begin{cases} 1 & \text{nếu Status = “Developing”} \\ 0 & \text{nếu Status = “Developed”} \end{cases} \quad (2.2)$$

Lý do sử dụng `drop_first=True`:

- Tránh **dummy variable trap**: Khi có k loại, chỉ cần $k - 1$ biến dummy
- Tránh **multicollinearity hoàn hảo**: Nếu giữ cả 2 cột, chúng có tương quan âm hoàn hảo (-1)
- Giảm chiều dữ liệu: Từ 1 cột phân loại thành 1 cột nhị phân thay vì 2 cột

Sau bước mã hóa, biến Status được thay thế bởi biến **Status_Developing** với giá trị 0 (Developed) hoặc 1 (Developing).

Kết quả sau tiền xử lý:

- Kích thước dữ liệu: **2938 hàng $\times$ 21 cột**
- Tổng số features: **20** (không tính target)
- Các biến đã được chuyển đổi sang dạng số, sẵn sàng cho các bước tiếp theo

2.4 Chuẩn hóa dữ liệu

Chuẩn hóa (Standardization) là một bước quan trọng trong tiền xử lý dữ liệu, đặc biệt với các mô hình học máy nhạy cảm với thang đo như SVM, KNN, Logistic Regression, và các phương pháp giảm chiều như PCA.

Tại sao cần chuẩn hóa?

Các biến trong bộ dữ liệu có đơn vị đo và phạm vi giá trị rất khác nhau:

- GDP: từ vài chục USD đến hàng chục nghìn USD
- Population: từ vài nghìn đến hàng tỷ người
- Tỷ lệ tiêm chủng: từ 0% đến 100%
- BMI: từ 10 đến 80

Nếu không chuẩn hóa, các biến có giá trị lớn sẽ chi phối quá trình học, trong khi các biến có giá trị nhỏ bị “lấn át”.

Phương pháp StandardScaler:

Nhóm sử dụng StandardScaler từ scikit-learn để chuẩn hóa dữ liệu theo phân phối chuẩn (normal distribution) với trung bình $\mu = 0$ và độ lệch chuẩn $\sigma = 1$.

Công thức chuẩn hóa:

$$x_{scaled} = \frac{x - \mu}{\sigma} \quad (2.3)$$

Trong đó:

- x là giá trị gốc
- μ là trung bình của feature: $\mu = \frac{1}{N} \sum_{i=1}^N x_i$
- σ là độ lệch chuẩn: $\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$

Quy trình thực hiện:

1. **Chia dữ liệu:** Trước khi chuẩn hóa, dữ liệu được chia thành tập huấn luyện (70%) và tập kiểm tra (30%) với `train_test_split`, sử dụng `random_state=42` để đảm bảo tính tái lập.

2. **Fit trên tập huấn luyện:** StandardScaler được fit (học tham số μ và σ) trên tập X_train để tránh **data leakage** (rò rỉ thông tin từ tập test).

3. **Transform cả hai tập:** Áp dụng phép biến đổi với cùng tham số đã học cho cả X_train và X_test.

Kết quả sau chuẩn hóa:

```
1 X_train_scaled: mean = -0.000000, std = 1.000000
2 X_test_scaled: mean ~ 0, std ~ 1
```

Dữ liệu đã được chuẩn hóa thành công, với các giá trị tập trung quanh 0 và độ phân tán đồng nhất. Điều này đảm bảo:

- Các feature có trọng số tương đương trong quá trình học
- Thuật toán hội tụ nhanh hơn
- Kết quả ổn định và đáng tin cậy hơn

Chương 3

Giảm chiều và trực quan hóa dữ liệu

3.1 Phân tích thành phần chính (PCA)

3.1.1 Mục đích

Phân tích thành phần chính (PCA) là phương pháp giảm chiều không giám sát, nhằm loại bỏ dư thừa và giữ lại các thành phần mang nhiều thông tin nhất. PCA biến đổi dữ liệu sang không gian mới với các trục tọa độ ít tương quan, giúp giảm chi phí tính toán, cải thiện hiệu suất mô hình và hỗ trợ trực quan hóa trong các bài toán dữ liệu có số chiều lớn.

Trong bài toán dự đoán tuổi thọ trung bình, PCA giúp:

- Giảm từ 20 đặc trưng xuống còn **15 thành phần chính** mà vẫn giữ **96.55% phương sai**.
- Loại bỏ đa cộng tuyến giữa các yếu tố như `Schooling` và `Income composition`.
- Trực quan hóa mối quan hệ giữa các chỉ số y tế - xã hội và tuổi thọ.

3.1.2 Cơ sở lý thuyết

Giả sử hệ cơ sở trực chuẩn mới là $\mathbf{U}$ và ta muốn giữ lại K tọa độ trong hệ cơ sở mới. Không mất tính tổng quát, giả sử đó là K thành phần đầu tiên.

The diagram illustrates the PCA decomposition of data matrix $\mathbf{X}$ into components $\mathbf{U}$, $\mathbf{Z}$, and $\mathbf{Y}$. It shows the following steps:

$$\begin{aligned} \begin{array}{|c|c|} \hline N \\ \hline D & \mathbf{X} \\ \hline \end{array} &= \begin{array}{|c|c|} \hline K & D-K \\ \hline D & \mathbf{U}_K & \bar{\mathbf{U}}_K \\ \hline \end{array} \times \begin{array}{|c|c|} \hline N \\ \hline K & \mathbf{Z} \\ \hline D-K & \mathbf{Y} \\ \hline \end{array} \\ &= \begin{array}{|c|} \hline K \\ \hline D & \mathbf{U}_K \\ \hline \end{array} \times \begin{array}{|c|c|} \hline N \\ \hline K & \mathbf{Z} & D \\ \hline \end{array} + \begin{array}{|c|} \hline D-K \\ \hline \bar{\mathbf{U}}_K \\ \hline \end{array} \times \begin{array}{|c|} \hline \mathbf{Y} \\ \hline \end{array} \end{aligned}$$

Labels below the matrices: Original data, An orthogonal matrix, Coordinates in new basis.

Trong hình minh họa, hệ cơ sở mới $\mathbf{U} = [\mathbf{U}_k, \bar{\mathbf{U}}_k]$ là hệ trực chuẩn với $\mathbf{U}_k$ là ma trận con tạo bởi k cột đầu tiên của $\mathbf{U}$.

Mục đích của PCA là tìm ma trận trực giao $\mathbf{U}$ sao cho phần lớn thông tin được giữ lại ở phần $\mathbf{U}_k \mathbf{Z}$ (phần màu xanh) và có thể lược bỏ phần $\bar{\mathbf{U}}_k \mathbf{Y}$ (phần màu đỏ) và thay bằng một ma trận không phụ thuộc vào điểm dữ liệu.

3.1.3 Các bước thực hiện

1. Tính vector kỳ vọng của toàn bộ dữ liệu:

$$\bar{\mathbf{x}} = \frac{1}{N} \sum_{n=1}^N \mathbf{x}_n$$

Trong đó $N = 2938$ là số lượng mẫu, và $\mathbf{x}_n$ là vector dữ liệu thứ n .

2. Tính dữ liệu chuẩn hóa $\hat{\mathbf{x}}_n$:

$$\hat{\mathbf{x}}_n = \mathbf{x}_n - \bar{\mathbf{x}}, \quad n = 1, 2, \dots, N.$$

3. Tính ma trận hiệp phương sai:

$$\mathbf{S} = \frac{1}{N} \hat{\mathbf{X}} \hat{\mathbf{X}}^T$$

Trong đó $\hat{\mathbf{X}}$ là ma trận dữ liệu đã được chuẩn hóa (sử dụng `StandardScaler`).

4. Tính các trị riêng λ_i và vector riêng $\mathbf{u}_i$ của ma trận hiệp phương sai.
5. Chọn k giá trị riêng lớn nhất và k vector riêng tương ứng để xây dựng ma trận $\mathbf{U}_k$.
Trong bài toán này: $k = 15$ (để giữ $\geq 95\%$ phương sai).
6. Các cột của $\{\mathbf{u}_j\}_{j=1}^k$ là hệ cơ sở trực chuẩn.
7. Chiếu dữ liệu ban đầu đã chuẩn hóa $\hat{\mathbf{X}}$ xuống không gian con mới:


$$\mathbf{Z} = \mathbf{U}_k^T \hat{\mathbf{X}}.$$

Ma trận $\mathbf{Z}$ chứa các biểu diễn nén của dữ liệu trên không gian có số chiều thấp hơn.

Dữ liệu ban đầu có thể được xấp xỉ lại từ dữ liệu nén như sau:

$$\mathbf{x} \approx \mathbf{U}_k \mathbf{Z} + \bar{\mathbf{x}}.$$


Trong đó $\mathbf{U}_k \mathbf{Z}$ là phần thông tin giữ lại và $\bar{\mathbf{x}}$ là trung bình của dữ liệu ban đầu được cộng lại để khôi phục vị trí gốc.



3.1.4 Kết quả thực nghiệm

- Số chiều gốc: 20 features (sau tiền xử lý).
- Số chiều sau PCA: 15 thành phần chính.
- Phương sai giải thích trên tập kiểm tra: 96.55%.
- Đánh giá tái tạo dữ liệu:


explained_variance_score = 0.9655



Hình 3.1: Phân tán dữ liệu theo 2 thành phần chính đầu tiên (PC1 vs PC2).

Nhận xét từ hình 3.1:


- **Gradient rõ rệt:** Từ tím (tuổi thọ thấp) → vàng (tuổi thọ cao).
- **PC1:** Đại diện cho mức độ phát triển (giáo dục, thu nhập, y tế).
- **PC2:** Liên quan đến BMI, tiêm chủng (Polio, Diphtheria).



Hình 3.2: Biểu đồ phân tán cho 6 cặp thành phần chính đầu tiên.

Nhận xét từ hình 3.2:

- **PC1 vs PC2:** Phân tách tốt nhất theo tuổi thọ.
- **PC1 vs PC3, PC1 vs PC5:** Vẫn có xu hướng, nhưng chồng lấn ở vùng trung bình.
- **PC3 vs PC4:** Phân bố ngẫu nhiên → đóng góp thấp.



Hình 3.3: Tương quan giữa các thành phần chính (PC1–PC15) và đặc trưng gốc.

PC1 (thành phần quan trọng nhất) có tương quan mạnh với:

- **Dương:** Schooling, Income composition, BMI
- **Âm:** Adult Mortality, HIV/AIDS, Status_Developing

→ PC1 đại diện cho **chỉ số phát triển con người và y tế công cộng**.

3.2 Lựa chọn đặc trưng với SelectKBest

3.2.1 Giới thiệu về SelectKBest

SelectKBest là một phương pháp feature selection (lựa chọn đặc trưng) thuộc loại supervised learning, có nghĩa là nó sử dụng thông tin từ biến mục tiêu (target) để đánh giá và chọn ra K features quan trọng nhất.

Ưu điểm:

- Giữ nguyên ý nghĩa của các features gốc (dễ diễn giải)
- Giảm số chiều dữ liệu, tránh overfitting
- Loại bỏ các features không có ý nghĩa thống kê
- Tăng tốc độ training model

Nhược điểm:

- Không xử lý multicollinearity (tương quan cao giữa các features)
- Đánh giá từng feature độc lập (không xem xét tương tác giữa các features)

3.2.2 Phương pháp f_regression

f_regression là hàm tính toán F-statistic giữa mỗi feature và target trong bài toán regression.

Công thức F-statistic:

$$F = \frac{MSR}{MSE} = \frac{SSR/1}{SSE/(n-2)} \quad (3.1)$$

Trong đó:

- SSR (Sum of Squares Regression): Tổng bình phương do hồi quy
- SSE (Sum of Squares Error): Tổng bình phương sai số
- n : Số mẫu dữ liệu

Ý nghĩa:

- F-statistic cao → Feature có mối quan hệ tuyến tính mạnh với target
- F-statistic thấp → Feature ít ảnh hưởng đến target

3.2.3 Kết quả thực nghiệm

Top 10 features quan trọng nhất theo F-statistic:

Thứ hạng	Feature	F-Score
1	Schooling	2186.35
2	Income composition of resources	1953.29
3	Adult Mortality	1936.17
4	HIV/AIDS	935.39
5	BMI	926.69
6	Status_Developing	613.14
7	thinness 5-9 years	596.04
8	thinness 1-19 years	590.59
9	Diphtheria	556.06
10	Polio	496.10

Bảng 3.1: Top 10 features quan trọng nhất

Nhận xét:

- **Schooling** (số năm học trung bình) là yếu tố quan trọng nhất, với F-score = 2186.35
- **Income composition of resources** và **Adult Mortality** cũng có ảnh hưởng rất lớn
- Các yếu tố y tế như HIV/AIDS, BMI, tỷ lệ tiêm chủng cũng đóng vai trò quan trọng
- Trạng thái phát triển (Developed/Developing) có ảnh hưởng đáng kể

Kích thước dữ liệu sau khi chọn K=10 features:

- X_train_kbest shape: (2056, 10)
- X_test_kbest shape: (882, 10)

3.3 So sánh PCA và SelectKBest

Bảng tổng hợp so sánh chi tiết giữa hai phương pháp:

Đặc điểm	PCA	SelectKBest
Loại phương pháp	Tuyến tính, unsupervised	Supervised
Mục đích chính	Giảm chiều cho modeling	Chọn features quan trọng
Số chiều đầu ra	15	10
Phương sai giải thích	96.55%	N/A
Transform dữ liệu mới	Có	Có
Giải thích được	Thấp	Cao
Bảo toàn ý nghĩa	Không	Có
Xử lý multicollinearity	Có	Không
Độ phức tạp	$O(d^2 \cdot N + d^3)$	$O(d \cdot N)$

Bảng 3.2: So sánh PCA và SelectKBest

Kết quả thực nghiệm:

- **PCA (15 components):** Giảm từ 20 xuống 15 chiều, giữ 96.55% phương sai
- **SelectKBest (10 features):** Giảm từ 20 xuống 10 chiều, giữ nguyên ý nghĩa features gốc

Kết luận:

Trong dự án này, nhóm sử dụng **cả hai phương pháp** để so sánh hiệu quả:

- **PCA** để giảm chiều và loại bỏ multicollinearity
- **SelectKBest** để chọn features quan trọng nhất, dễ diễn giải

Chương 4

Phương pháp hồi quy sử dụng KNN

4.1 Giới thiệu

K-nearest neighbor là một trong những thuật toán supervised-learning đơn giản nhất trong Machine Learning. Khi training, thuật toán này không học một điều gì từ dữ liệu huấn luyện, mọi tính toán được thực hiện khi nó cần dự đoán kết quả của dữ liệu mới. Knearest neighbor có thể áp dụng được vào cả hai loại của bài toán Supervised learning là Classification và Regression.



Hình 4.1: Minh họa thuật toán K-Nearest Neighbor.

4.2 Cách thuật toán KNN hoạt động trong bài toán hồi quy

Thuật toán **K-Nearest Neighbors Regression (KNN Regression)** là một phương pháp hồi quy phi tham số (*non-parametric regression*), nghĩa là nó không giả định trước dạng hàm quan hệ giữa đầu vào x và đầu ra y . Thay vào đó, dự đoán đầu ra của một điểm mới được thực hiện dựa trên sự tương đồng (về khoảng cách) với các điểm đã biết trong tập dữ liệu huấn luyện.

4.2.1 Ý tưởng tổng quát

Giả sử ta có tập dữ liệu huấn luyện:

$$\mathcal{D} = \{(x^{(i)}, y^{(i)}) \mid i = 1, 2, \dots, N\}, \quad x^{(i)} \in \mathbb{R}^d, \quad y^{(i)} \in \mathbb{R}.$$

Khi cần dự đoán giá trị $\hat{y}$ cho một điểm mới x , thuật toán KNN sẽ thực hiện các bước:

1. Tính khoảng cách giữa x và mọi điểm $x^{(i)}$ trong tập huấn luyện.
2. Chọn ra k điểm có khoảng cách nhỏ nhất — gọi là **k hàng xóm gần nhất**.
3. Dự đoán giá trị $\hat{y}$ bằng cách lấy trung bình (hoặc trung bình có trọng số) các giá trị $y^{(i)}$ tương ứng với k hàng xóm đó.

4.2.2 Tính khoảng cách giữa các điểm

Trong thuật toán KNN, việc đo lường **khoảng cách** giữa điểm cần dự đoán x và các điểm dữ liệu huấn luyện $x^{(i)}$ là bước quan trọng để xác định các *láng giềng gần nhất*.

(a) Trường hợp dữ liệu một chiều: Khi dữ liệu chỉ có một thuộc tính ($d = 1$), khoảng cách giữa hai điểm x và $x^{(i)}$ được tính đơn giản như sau:

$$d(x, x^{(i)}) = |x - x^{(i)}|.$$

Khoảng cách này thể hiện độ chênh lệch tuyệt đối giữa hai giá trị trên trục số.

(b) Trường hợp dữ liệu nhiều chiều: Khi dữ liệu có nhiều thuộc tính ($d > 1$), ta cần sử dụng các công thức đo khoảng cách tổng quát hơn. Khoảng cách phổ biến nhất là **khoảng cách Euclid (Euclidean distance)**:

$$d(x, x^{(i)}) = \sqrt{\sum_{j=1}^d (x_j - x_j^{(i)})^2}.$$

Ngoài ra, có thể sử dụng các biến thể khác:

$$\text{Manhattan: } d_1(x, x^{(i)}) = \sum_{j=1}^d |x_j - x_j^{(i)}|, \quad \text{Minkowski: } d_p(x, x^{(i)}) = \left(\sum_{j=1}^d |x_j - x_j^{(i)}|^p \right)^{1/p}.$$

Trong đó:

- d là số chiều của dữ liệu (số thuộc tính).
- x_j và $x_j^{(i)}$ là giá trị của thuộc tính thứ j của điểm x và $x^{(i)}$.
- p là tham số điều chỉnh độ nhạy của khoảng cách Minkowski (khi $p = 2$ thì là Euclid, khi $p = 1$ thì là Manhattan).

4.2.3 Chuẩn hóa dữ liệu (Feature Scaling)

Vì mỗi đặc trưng x_j có thể nằm trên thang đo khác nhau (ví dụ: GDP có thể hàng nghìn, BMI chỉ vài chục), việc chuẩn hóa là cần thiết để đảm bảo mọi đặc trưng có ảnh hưởng công bằng trong tính toán khoảng cách. Hai cách phổ biến:

$$z = \frac{x - \mu}{\sigma} \quad (\text{StandardScaler}), \quad z = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (\text{MinMaxScaler}).$$

4.2.4 Cách tính giá trị dự đoán

Giả sử $N_k(x)$ là tập chỉ số của k hàng xóm gần nhất của x .

(a) Trung bình đều (Uniform weights):

$$\hat{y}(x) = \frac{1}{k} \sum_{i \in N_k(x)} y^{(i)}.$$

(b) Trung bình có trọng số theo khoảng cách (Distance-weighted):

$$\hat{y}(x) = \frac{\sum_{i \in N_k(x)} w_i y^{(i)}}{\sum_{i \in N_k(x)} w_i}, \quad \text{với } w_i = \frac{1}{d(x, x^{(i)}) + \varepsilon},$$

trong đó ε là hằng số nhỏ để tránh chia cho 0.

4.2.5 Quy trình thuật toán (pseudocode)

Algorithm 1 Thuật toán KNN Regression

Require: Tập huấn luyện $\mathcal{D}$, số hàng xóm k , điểm cần dự đoán x , loại khoảng cách $d(\cdot, \cdot)$

Ensure: Giá trị dự đoán $\hat{y}(x)$

- 1: Tính $d_i = d(x, x^{(i)})$ với mọi $i = 1, \dots, N$
 - 2: Sắp xếp các d_i tăng dần và lấy k hàng xóm gần nhất $N_k(x)$
 - 3: $\hat{y}(x) = \frac{1}{k} \sum_{i \in N_k(x)} y^{(i)}$
 - 4: **return** $\hat{y}(x)$
-

4.2.6 Chọn giá trị k phù hợp

- Nếu k nhỏ $\Rightarrow$ mô hình phản ứng nhanh nhưng dễ bị nhiễu (overfitting).
- Nếu k lớn $\Rightarrow$ mô hình mượt hơn nhưng có thể làm mất chi tiết (underfitting).
- Có thể dùng *cross-validation* để chọn k tối ưu bằng cách thử nhiều giá trị k và chọn sai số nhỏ nhất.
- Trong bài toán dự đoán ta sử dụng $k = \sqrt{n}$

4.2.7 Đánh giá hiệu quả mô hình

Sử dụng các chỉ số đánh giá:

$$\text{MAE} = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|, \quad \text{MSE} = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2, \quad R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}.$$

4.2.8 Tóm tắt

KNN Regression dựa trên giả định:

“Các điểm có đặc trưng giống nhau thì giá trị đầu ra cũng gần nhau.”

Mô hình không cần huấn luyện phức tạp, chỉ cần lưu trữ dữ liệu và tính khoảng cách khi dự đoán. Nhược điểm là chi phí tính toán cao khi dữ liệu lớn.

4.3 Phương pháp KNN với bài toán hồi quy dự đoán tuổi thọ trung bình

4.3.1 Đánh giá hiệu suất mô hình theo các tỉ lệ chia dữ liệu

Để đánh giá hiệu suất của mô hình KNN Regression trong bài toán dự đoán *tuổi thọ trung bình*, ta tiến hành thử nghiệm với ba tỉ lệ chia tập dữ liệu huấn luyện và kiểm định: **80:20**, **70:30** và **60:40**. Ba dạng dữ liệu được sử dụng gồm:

- **Dữ liệu gốc:** Toàn bộ các đặc trưng sau khi chuẩn hoá.
- **Dữ liệu PCA:** Dữ liệu sau khi giảm chiều bằng phương pháp *Principal Component Analysis*.
- **Dữ liệu SelectKBest:** Dữ liệu sau khi chọn ra các đặc trưng quan trọng nhất bằng *SelectKBest*.

4.3.2 Kết quả thực nghiệm

Tỉ lệ	Dữ liệu	Train R^2	Test R^2	ΔR^2	Train MSE	Test MSE	RMSE
80:20 (4:1)	Gốc	0.8982	0.8758	0.0224	8.9641	12.3597	3.5156
70:30 (7:3)	Gốc	0.8967	0.8718	0.0249	9.0967	12.2710	3.5030
60:40 (6:4)	Gốc	0.8963	0.8770	0.0193	9.2961	11.2456	3.3535
80:20 (4:1)	PCA	0.8531	0.8348	0.0183	12.9346	16.4362	4.0542
70:30 (7:3)	PCA	0.8514	0.8306	0.0208	13.0837	16.2091	4.0260
60:40 (6:4)	PCA	0.8470	0.8325	0.0145	13.7199	15.3172	3.9137
80:20 (4:1)	SelectKBest	0.8995	0.8832	0.0162	8.8528	11.6199	3.4088
70:30 (7:3)	SelectKBest	0.8986	0.8820	0.0166	8.9228	11.2931	3.3605
60:40 (6:4)	SelectKBest	0.8976	0.8860	0.0116	9.1787	10.4247	3.2287

Bảng 4.1: So sánh kết quả huấn luyện và kiểm thử của ba phương pháp (dữ liệu gốc, PCA, và SelectKBest) theo các tỉ lệ chia dữ liệu khác nhau.

4.3.3 Phân tích kết quả


Kết quả cho thấy mô hình KNN hoạt động ổn định trên tất cả các tỉ lệ chia dữ liệu. Giá trị R^2 trên tập kiểm định dao động trong khoảng **0.83–0.89**, thể hiện khả năng dự đoán khá tốt và ổn định.

(1) So sánh giữa các loại dữ liệu:


- **Dữ liệu gốc:** Cho kết quả khá tốt, R_{test}^2 cao nhất đạt 0.877 ở tỉ lệ 60:40. Tuy nhiên, độ chênh ΔR^2 dao động quanh 0.02–0.025, cho thấy mô hình vẫn có xu hướng hơi khớp quá nhẹ.
- **Dữ liệu PCA:** Có R_{test}^2 thấp hơn so với hai dạng còn lại (tối đa 0.8348), cho thấy việc giảm chiều bằng PCA làm mất mát một phần thông tin quan trọng.
- **Dữ liệu SelectKBest:** Cho hiệu quả tốt nhất. R_{test}^2 cao nhất đạt **0.886**, MSE thấp nhất chỉ **10.4247**, và ΔR^2 nhỏ nhất **0.0116**, thể hiện khả năng học và tổng quát hoá cân bằng nhất.

(2) **Ảnh hưởng của tỉ lệ chia dữ liệu:** Khi giảm tỉ lệ train (từ 80:20 xuống 60:40), R_{test}^2 hầu như không giảm mà có xu hướng tăng nhẹ (đặc biệt ở SelectKBest). Điều này cho thấy tập dữ liệu đủ lớn và mô hình KNN có tính ổn định cao. Sự thay đổi nhỏ trong R_{test}^2 (< 0.01) chứng minh khả năng tổng quát tốt của mô hình.

(3) **Độ chênh lệch ΔR^2 và hiện tượng overfitting:** Giá trị $\Delta R^2 = |R_{train}^2 - R_{test}^2|$ được sử dụng để đo độ khớp quá (overfit). Tất cả các giá trị ΔR^2 đều **dưới 0.05**, nằm dưới ngưỡng cảnh báo (đường đỏ trên hình 4.3). Điều này chứng tỏ mô hình **không bị overfitting** ở bất kỳ dạng dữ liệu nào.




Hình 4.2: So sánh giá trị R^2 trên tập kiểm định theo tỉ lệ chia dữ liệu.




Hình 4.3: So sánh độ chênh lệch ΔR^2 giữa tập huấn luyện và kiểm định.


4.3.4 Trực quan hóa phần dư



(a) Ảnh trực quan hóa phần dư (giảm chiều pca)



(b) Ảnh trực quan hóa phần dư trong trường hợp gốc



(c) Ảnh trực quan hóa phần dư trong trường hợp giảm chiều select k best

Hình 4.4: Các biểu đồ trực quan hóa phần dư

Nhận xét:

- Ta có thể thấy các giá trị *residual* phân bố ngẫu nhiên xung quanh trục giá trị 0.

- Việc lựa chọn giá trị K cho cả ba trường hợp là hợp lý, giúp mô hình dự đoán được đa số dữ liệu.
- Việc sử dụng mô hình *K-Nearest Neighbors (KNN)* là phù hợp.

4.3.5 Nhận xét tổng quan

Phương pháp KNN Regression cho thấy hiệu quả cao trong bài toán dự đoán tuổi thọ trung bình. Các kết luận chính:

- **SelectKBest** giúp cải thiện rõ rệt hiệu suất, mang lại R_{test}^2 và MSE tốt nhất.
- Mô hình duy trì tính ổn định với các tỉ lệ chia khác nhau, không có dấu hiệu overfit.
- **PCA** mang lại lợi ích không nhiều cho bài toán này.

Tổng kết lại, mô hình KNN Regression kết hợp **SelectKBest** là lựa chọn phù hợp, vừa đảm bảo hiệu quả dự đoán, vừa tránh được hiện tượng khớp quá, đồng thời hoạt động ổn định trên các tỉ lệ chia dữ liệu khác nhau.

Chương 5

Phương pháp Linear Regression với bài toán hồi quy dự đoán tuổi thọ trung bình

5.1 Cách thuật toán Linear Regression hoạt động

5.1.1 Mô hình tổng quát

Thuật toán **Linear Regression (Hồi quy tuyến tính)** mô hình hóa mối quan hệ giữa biến đầu ra y (trong bài toán này là **tuổi thọ trung bình**) và các biến đầu vào $x_1, x_2, \dots, x_n$ (các yếu tố y tế - xã hội như GDP, BMI, tỷ lệ tiêm chủng, v.v.) theo dạng tuyến tính:

$$\hat{y} = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n = \mathbf{w}^T \mathbf{x} + w_0,$$

trong đó:

- $\hat{y}$: giá trị tuổi thọ trung bình dự đoán.
- $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$: vector đặc trưng đầu vào.
- $\mathbf{w} = [w_1, w_2, \dots, w_n]^T$: vector trọng số của mô hình.
- w_0 : hệ số chặn (bias term).

5.1.2 Hàm mất mát (Loss function)

Để tìm được các trọng số w_i tối ưu, ta cần giảm thiểu sai số giữa giá trị dự đoán $\hat{y}^{(i)}$ và giá trị thực tế $y^{(i)}$. Sai số này được đo bằng **hàm mất mát bình phương trung bình** (Mean Squared Error - MSE):

$$J(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \left(\hat{y}^{(i)} - y^{(i)} \right)^2 = \frac{1}{m} \sum_{i=1}^m \left(\mathbf{w}^T \mathbf{x}^{(i)} + w_0 - y^{(i)} \right)^2,$$

trong đó m là số lượng mẫu trong tập huấn luyện.

5.1.3 Quá trình huấn luyện mô hình

Mục tiêu của quá trình huấn luyện là tìm bộ tham số $\mathbf{w}$ và w_0 sao cho $J(\mathbf{w})$ đạt giá trị nhỏ nhất. Có hai cách phổ biến để thực hiện việc này:

1. **Công thức đóng (Closed-form solution):**

$$\mathbf{w} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y},$$

trong đó $\mathbf{X}$ là ma trận đặc trưng đầu vào, $\mathbf{y}$ là vector giá trị thực tế.

2. **Phương pháp Gradient Descent:** Cập nhật trọng số qua từng bước:

$$w_j := w_j - \alpha \frac{\partial J}{\partial w_j}, \quad \text{với } \frac{\partial J}{\partial w_j} = \frac{2}{m} \sum_{i=1}^m (\hat{y}^{(i)} - y^{(i)}) x_j^{(i)},$$

trong đó α là tốc độ học (learning rate).

5.1.4 Dự đoán giá trị tuổi thọ trung bình

Sau khi huấn luyện, mô hình sử dụng các trọng số tối ưu $\mathbf{w}^*$ để dự đoán tuổi thọ trung bình cho một quốc gia mới:

$$\hat{y}_{\text{new}} = \mathbf{w}^{*T} \mathbf{x}_{\text{new}} + w_0^*.$$

5.1.5 Ưu và nhược điểm

Ưu điểm:

- Dễ hiểu, nhanh, và có thể giải thích được mối quan hệ giữa các biến.
- Thích hợp khi mối quan hệ giữa các đặc trưng và biến mục tiêu là gần tuyến tính.

Nhược điểm:

- Hiệu quả kém khi dữ liệu có quan hệ phi tuyến tính.
- Dễ bị ảnh hưởng bởi các ngoại lai (outliers).

5.2 Đánh giá hiệu suất mô hình theo các tỉ lệ chia dữ liệu

Để đánh giá hiệu suất của mô hình **Linear Regression** trong bài toán dự đoán *tuổi thọ trung bình*, ta tiến hành thử nghiệm với ba tỉ lệ chia tập dữ liệu huấn luyện và kiểm định: **80:20**, **70:30** và **60:40**. Các phép thử được thực hiện trên ba dạng dữ liệu khác nhau:

- **Dữ liệu gốc:** Toàn bộ các đặc trưng sau khi được chuẩn hoá.
- **Dữ liệu PCA:** Dữ liệu sau khi giảm chiều bằng phương pháp *Principal Component Analysis*.
- **Dữ liệu SelectKBest:** Dữ liệu sau khi chọn ra các đặc trưng quan trọng nhất bằng phương pháp *SelectKBest*.

5.2.1 Kết quả thực nghiệm

Tỉ lệ	Dữ liệu	Train R^2	Test R^2	ΔR^2	Train MSE	Test MSE
80:20	Gốc	0.8220	0.8093	0.0126	16.0669	17.2679
70:30	Gốc	0.8220	0.8126	0.0095	15.8402	17.5262
60:40	Gốc	0.8253	0.8100	0.0153	15.8734	17.0314
80:20	PCA	0.8114	0.7993	0.0121	17.0236	18.1756
70:30	PCA	0.8112	0.8031	0.0081	16.8019	18.4058
60:40	PCA	0.8149	0.7997	0.0151	16.8195	17.9531
80:20	SelectKBest	0.8062	0.7985	0.0077	17.4916	18.2484
70:30	SelectKBest	0.8057	0.8017	0.0040	17.2939	18.5390
60:40	SelectKBest	0.8090	0.7979	0.0111	17.3492	18.1168

Bảng 5.1: Kết quả so sánh hiệu suất mô hình Linear Regression theo tỉ lệ chia dữ liệu

5.2.2 Phân tích kết quả


Kết quả cho thấy mô hình Linear Regression hoạt động ổn định và nhất quán trên cả ba loại dữ liệu. Giá trị R^2 trên tập kiểm định dao động trong khoảng **0.79–0.82**, thể hiện khả năng mô hình hoá tương đối tốt của hồi quy tuyến tính trong bài toán dự đoán tuổi thọ trung bình.

(1) So sánh giữa các loại dữ liệu:


- **Dữ liệu gốc:** Cho kết quả R_{test}^2 cao nhất (đạt tới 0.8126 tại tỉ lệ 70:30), cho thấy mô hình hoạt động tốt nhất khi sử dụng toàn bộ đặc trưng ban đầu.
- **Dữ liệu PCA:** Hiệu suất giảm nhẹ (dao động quanh 0.799–0.803), cho thấy việc giảm chiều bằng PCA có thể làm mất đi một phần thông tin có ích cho mô hình tuyến tính.
- **Dữ liệu SelectKBest:** Cho kết quả ổn định nhất, với ΔR^2 nhỏ nhất chỉ **0.0040** ở tỉ lệ 70:30, thể hiện khả năng tổng quát hoá tốt nhất trong ba dạng dữ liệu.

(2) Ảnh hưởng của tỉ lệ chia dữ liệu: Khi tỉ lệ tập huấn luyện giảm (từ 80:20 sang 60:40), R_{test}^2 giảm nhẹ, đặc biệt ở dữ liệu PCA và SelectKBest. Tuy nhiên, mức giảm này không đáng kể ($\Delta R^2 < 0.01$), cho thấy mô hình Linear Regression có độ ổn định tốt và không quá nhạy cảm với kích thước tập huấn luyện. Hiệu suất cao nhất nhìn chung đạt được ở tỉ lệ chia **70:30**, thể hiện sự cân bằng giữa lượng dữ liệu huấn luyện và kiểm định.

(3) Độ chênh lệch ΔR^2 và hiện tượng overfitting: Giá trị $\Delta R^2 = |R_{train}^2 - R_{test}^2|$ được dùng để đánh giá mức độ khớp quá (overfit). Kết quả cho thấy tất cả các trường hợp đều có $\Delta R^2 < 0.05$, nằm dưới ngưỡng cảnh báo overfit (đường đỏ trên hình 5.2). Điều này chứng tỏ mô hình **Linear Regression không bị overfitting** và có khả năng tổng quát tốt trên dữ liệu kiểm định.




Hình 5.1: So sánh giá trị R^2 trên tập kiểm định theo tỉ lệ chia dữ liệu.




Hình 5.2: So sánh độ chênh lệch ΔR^2 giữa tập huấn luyện và kiểm định.


5.2.3 Trực quan hóa phần dư



(a) Ảnh trực quan hóa phần dư (giảm chiều pca)



(b) Ảnh trực quan hóa phần dư trong trường hợp gốc



(c) Ảnh trực quan hóa phần dư trong trường hợp giảm chiều select k best

Hình 5.3: Các biểu đồ trực quan hóa phần dư

Nhận xét:

- Mean residual $\approx 0 \rightarrow$ Mô hình không bị bias hệ thống.
- Phân bố residuals ngẫu nhiên quanh đường $y=0 \rightarrow$ giả định tuyến tính được thỏa mãn.
- Không có hình nón/phễu rõ ràng $\rightarrow$ phương sai đồng nhất được đảm bảo.
- Việc sử dụng mô hình Linear Regression là phù hợp.

5.3 Nhận xét tổng quan

Phương pháp **Linear Regression** cho thấy hiệu suất ổn định trong bài toán dự đoán tuổi thọ trung bình, với mức độ khớp mô hình và sai số trung bình hợp lý. Cụ thể:

- Mô hình đạt hiệu suất cao nhất ở tỉ lệ chia dữ liệu **70:30**.
- Tất cả các trường hợp đều có $\Delta R^2 < 0.05$, **không xuất hiện hiện tượng overfitting**.
- Dữ liệu gốc đạt R^2_{test} cao nhất, trong khi dữ liệu **SelectKBest** cho thấy khả năng tổng quát ổn định hơn.
- Giảm chiều bằng PCA chưa mang lại lợi ích rõ rệt so với việc chọn đặc trưng có trọng số cao.

Từ các kết quả trên, có thể kết luận rằng mô hình Linear Regression tuy đơn giản nhưng vẫn mang lại hiệu quả tốt và độ ổn định cao, phù hợp cho việc dự đoán các xu hướng tuyến tính trong dữ liệu tuổi thọ trung bình.

Chương 6

Kết luận

Dự án đã hoàn thành toàn diện quy trình phân tích và dự đoán tuổi thọ trung bình dựa trên các yếu tố y tế - xã hội, từ tiền xử lý dữ liệu, giảm chiều, đến đánh giá hiệu suất các mô hình hồi quy. Các kết quả chính được tóm tắt như sau:

1. Tiền xử lý dữ liệu

- Xử lý thành công **2563 giá trị thiếu (3.97%)** bằng phương pháp `SimpleImputer(strategy='mean')`, đảm bảo không còn giá trị NaN.
- Loại bỏ cột Country (193 giá trị duy nhất) để tránh *curse of dimensionality*; thay vào đó, thông tin địa lý được biểu diễn gián tiếp qua GDP, Schooling, Status.
- Mã hóa One-Hot cho biến Status (Developed/Developing) với `drop_first=True` để tránh đa cộng tuyến.
- Chuẩn hóa dữ liệu bằng `StandardScaler`: $\text{mean} \approx 0$, $\text{std} \approx 1$, đảm bảo tính ổn định cho các mô hình nhạy cảm với thang đo.

2. Giảm chiều dữ liệu

- **PCA**: Giảm từ 20 chiều xuống **15 thành phần chính** (giảm 25%), giữ lại **95% phương sai** trên tập huấn luyện và **96.55%** trên tập kiểm tra. Thành phần chính đầu tiên (PC1) giải thích $\sim 42\%$ phương sai, đại diện cho trục *phát triển kinh tế - xã hội*.
- **SelectKBest (f_regression)**: Chọn **10 đặc trưng quan trọng nhất**, bao gồm: Schooling, Income composition, Adult Mortality, HIV/AIDS, BMI, Polio, Diphtheria, thinness, Status_Developing.
- So sánh: PCA giảm chiều không giám sát, giữ variance tốt; SelectKBest giám sát, giữ nguyên ý nghĩa đặc trưng, dễ diễn giải.

3. Đánh giá mô hình hồi quy

Hai mô hình **KNN Regressor** và **Linear Regression** được thử nghiệm trên 3 loại dữ liệu (*gốc*, *PCA*, *SelectKBest*) với 3 tỉ lệ chia: 80:20, 70:30, 60:40.

3.1. K-Nearest Neighbors (KNN)

- Sử dụng $k = \lfloor \sqrt{n} \rfloor$, khoảng cách Manhattan, `weights=uniform`.
- **Kết quả nổi bật:**
 - Dữ liệu **SelectKBest** đạt **Test R^2 cao nhất: 0.886** (60:40), **MSE = 3.23**.
 - Dữ liệu **gốc**: Test $R^2 \in [0.872, 0.877]$, $MSE \approx 3.5$.
 - **PCA**: Test R^2 thấp nhất (≈ 0.83), MSE cao nhất (≈ 4.0).
- **Overfit**: Không xảy ra ($\Delta R^2 < 0.05$ trong mọi trường hợp).
- **SelectKBest giảm ΔR^2 trung bình 33.3%** so với dữ liệu gốc $\rightarrow$ **mô hình ổn định và chính xác nhất**.

3.2. Linear Regression

- Dữ liệu gốc cho **Test R^2 cao nhất: 0.806** (70:30), $MSE \approx 16.85$.
- **PCA**: Test $R^2 \approx 0.79$, giảm ΔR^2 trung bình **13.0%** so với gốc $\rightarrow$ cải thiện tổng quát hóa.
- **SelectKBest**: Test $R^2 \approx 0.78$ – 0.79 , hiệu suất thấp hơn gốc nhưng vẫn ổn định.
- **Tỉ lệ 70:30 là tối ưu** cho cả hai mô hình: cân bằng giữa độ chính xác và độ ổn định.

4. Ý nghĩa thực tiễn

- Xác định các yếu tố then chốt ảnh hưởng đến tuổi thọ: `Schooling`, `Income composition`, `Adult Mortality`, `HIV/AIDS`.
- Hỗ trợ **nhà hoạch định chính sách** ưu tiên đầu tư vào giáo dục, y tế cơ bản, kiểm soát dịch bệnh.
- **Dự báo xu hướng tuổi thọ** theo kịch bản phát triển kinh tế - xã hội.

5. Hạn chế và hướng phát triển

- **Hạn chế:**
 - Dữ liệu chỉ đến năm 2015 $\rightarrow$ cần cập nhật dữ liệu gần đây.
 - Mean Imputation có thể làm giảm phương sai, gây bias nhẹ.
 - Chưa khai thác đầy đủ *mối quan hệ phi tuyến* giữa các biến.
 - KNN tốn tài nguyên tính toán khi dữ liệu lớn.
- **Hướng phát triển:**
 - Thử nghiệm mô hình phi tuyến: `Random Forest`, `XGBoost`, `SVR`.
 - Áp dụng `Ridge/Lasso` để kiểm soát đa cộng tuyến và cải thiện Linear Regression.
 - Sử dụng `Cross-validation` (5-fold, 10-fold) thay vì chia đơn.
 - Phân tích độ quan trọng đặc trưng bằng `SHAP` hoặc `Permutation Importance`.
 - Xây dựng **dashboard tương tác** (`Streamlit/Dash`) để trực quan hóa dự đoán theo quốc gia/năm.
 - Mở rộng dữ liệu: thêm biến khí hậu, đô thị hóa, ô nhiễm.

Tóm lại

Dự án đã xây dựng thành công một **hệ thống phân tích và dự đoán tuổi thọ toàn diện**, với:

- Quy trình tiền xử lý sạch, chuẩn hóa.
- Hai phương pháp giảm chiều hiệu quả: **PCA (giữ variance)** và **SelectKBest (giữ ý nghĩa)**.
- **SelectKBest + KNN** là tổ hợp tốt nhất: **$R^2 = 0.886$** , **MSE = 3.23**, không overfit.
- **Tỉ lệ train:test 70:30** là tối ưu cho cả KNN và Linear Regression.

Kết quả tạo nền tảng vững chắc cho giai đoạn tiếp theo: **xây dựng mô hình dự đoán chính xác cao, triển khai thực tế**.

Tài liệu tham khảo

- [1] TS. Cao Văn Chung, *Giáo trình môn học Học máy*, Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Hà Nội, 2025.
- [2] World Health Organization, *Life Expectancy Data*, <https://www.kaggle.com/datasets/kumarajarshi/life-expectancy-who>
- [3] Scikit-learn Documentation, *Principal Component Analysis (PCA)*, <https://scikit-learn.org/stable/modules/decomposition.html#pca>
- [4] L. van der Maaten and G. Hinton, “Visualizing Data using t-SNE”, *Journal of Machine Learning Research*, vol. 9, pp. 2579-2605, 2008.
- [5] Pandas Development Team, *pandas: powerful Python data analysis toolkit*, <https://pandas.pydata.org/>